



安徽大学
人工智能学院
School of Artificial Intelligence
Anhui University

人工智能伦理与安全课程大作业

透明与黑箱：高风险领域中 XAI 的必要性与实现路径

学 院： 人工智能学院

专 业： 人工智能

学 生： 杨跃浙 WA2214014

指导老师： 谭春雨

课程编号： ZH52016

课程学分： 1

提交日期： 25.11.20

摘要

深度学习推动了人工智能在医疗诊断、金融风控、司法辅助和公共治理等高风险领域的快速渗透。然而，这些模型往往以不可透明的“黑箱”形式运行，其内部表征和决策机制对开发者、领域专家及监管者均难以直接理解。这种不透明性在高风险情境下会放大错误决策、结构性偏差与安全攻击的后果，进而引发伦理、法律与社会信任等系统性问题。

本文结合近年来原型学习与结构可解释模型的研究进展，提出一个面向高风险场景的“解释性需求三维框架”，从风险类型、责任结构与用户角色三个维度刻画解释的必然性与差异化需求。随后，本文借助该框架分析黑箱模型在医疗与金融等领域可能产生的具体风险机理，论证在此类场景中仅依赖高性能而忽视可解释性是不可接受的。

在技术层面，本文将现有可解释人工智能（XAI）方法归纳为内在可解释模型、后置解释方法与结构可解释模型三类，并重点讨论原型学习方法，系统评估其在高风险应用中的潜力与局限。进一步地，本文剖析现实部署中实现有效可解释性所面临的关键挑战，包括性能与可解释性的结构性张力、解释稳定性与鲁棒性不足、语义一致性难题以及多角色异质化解释需求，并讨论相应的研究路径和制度性解决方案。

关键词：可解释人工智能；高风险领域；黑箱模型；原型学习

Abstract

Deep learning has accelerated the adoption of AI in high-risk domains such as medical diagnosis, financial risk management, judicial decision support, and public governance. Yet these systems often function as opaque “black boxes,” whose internal representations and decision processes are difficult for developers, domain experts, and regulators to understand. In high-stakes contexts, such opacity amplifies the consequences of errors, biases, and security vulnerabilities, creating ethical, legal, and societal risks.

Building on recent progress in prototype learning and structurally interpretable models, this paper proposes a three-dimensional framework of interpretability requirements for high-risk settings, spanning risk types, responsibility structures, and user roles. Using this framework, we analyze how black-box models can generate specific risks in healthcare and finance, arguing that high performance alone is insufficient and that interpretability is essential.

Technically, the paper groups existing Explainable AI (XAI) approaches into intrinsically interpretable models, post-hoc explanation methods, and structurally interpretable models, with a particular focus on prototype learning. We assess its strengths and limitations in high-risk applications. Finally, we discuss key deployment challenges—such as the performance–interpretability trade-off, instability and fragility of explanations, semantic misalignment, and heterogeneous user needs—along with potential research directions and institutional solutions.

Keywords: Explainable AI; High-risk domains; Black-box models; Prototype learning

目 录

1	引言	4
2	背景与相关工作	4
2.1	高风险 AI 与监管语境	4
2.2	可解释性概念与 Linardatos 等的分类	5
2.3	原型学习与结构可解释模型	5
3	高风险场景中的解释性需求三维框架	5
3.1	风险类型维度	5
3.2	责任结构维度	6
3.3	用户角色维度	6
4	黑箱模型在高风险领域的风险机制	7
5	可解释人工智能的技术路径：从透明模型到原型学习	7
5.1	内在可解释模型	8
5.2	后置解释方法	8
5.3	结构可解释模型与原型学习	8
6	现实部署中的挑战与潜在解决路径	9
6.1	性能与可解释性的结构性张力	9
6.2	解释方法的稳定性与验证难题	9
6.3	语义一致性与人类概念对齐	10
6.4	多角色异质化需求与系统级设计	10
6.5	评价体系与监管框架的缺失	10
7	结论与展望	10

1 引言

近年来，深度神经网络在图像识别、自然语言处理和结构化数据建模等任务上取得了突破性进展，推动了医疗影像诊断、辅助病理分析、自动化信贷评估、量化交易和刑事司法辅助等系统的快速发展。这些应用场景具有一个共通特征：模型输出将直接或间接作用于个体生命健康、财产安全和基本权利，属于典型的高风险 AI 系统。欧盟《人工智能法案》(EU AI Act)¹ 等监管文件已将医疗设备决策支持系统、用于信贷审批和执法的算法明确列入高风险类别，要求其满足严格的透明度与可解释性要求。

然而，当前主流的深度学习模型通常被视为“黑箱”：其内部高维表示和决策边界难以通过人类直观理解。模型虽然在测试集上表现出色，但缺乏清晰的因果解释和可审计机制。正如²所指出的，模型性能与可解释性之间存在深刻而尚未充分刻画的张力。对于自动推荐和广告投放等低风险领域，黑箱模型或许在实践中可以被宽容接受；但在医疗、金融和司法等高风险场景中，不透明性本身即构成独立风险源。

在可解释人工智能 (XAI) 方面，近年来已出现大量方法和综述。特别是³对机器学习可解释性方法进行了系统性的分类与评估，从透明模型与后置解释、模型依赖与模型无关、局部与全局等维度构建了较为完整的技术图景。然而，现有综述多以方法论视角出发，对为何在高风险领域必须是可解释的，不同用户群体需要何种解释，以及哪些解释是足以支撑责任追溯与合规审计的问题讨论不足。

另一方面，近年来，大量基于原型 (prototype) 的结构可解释模型涌现，其中以 ProtoPNet⁴、Neural Prototype Trees⁵ 等为代表的方法试图在保持深度网络表达能力的同时，赋予其接近“以例证说理”的可解释结构。这类方法在医疗影像等任务中显示出与临床思维模式相契合的潜力，是连接高性能与人类可理解性的有前景路径。

本文尝试将上述两条研究脉络结合起来：在现有 XAI 方法论综述的基础上，面向高风险情境提出一个解释性需求的理论框架，并在此框架下重审原型学习等结构可解释模型的价值与限制。与已有工作的主要区别在于，本文不再将可解释性视作抽象的“好属性”，而是从风险类型、责任结构与用户角色三个维度出发，分析在何种条件下、不具备何种解释将导致哪些具体风险，从而论证在高风险领域中可解释性不是可选项，而是系统设计的基本约束。

2 背景与相关工作

2.1 高风险 AI 与监管语境

“高风险 AI”并非仅指预测错误代价高昂的系统，还指其错误会对社会公正、基本权利和关键基础设施运行造成系统性影响。医疗诊断辅助系统可能影响诊疗路径和生存率；自动化信贷模型可能造成群体性信贷排斥；司法量刑支持系统的不公正偏差可能固化和放大结构性不平等。这些场景中的 AI 不能被视作单纯的“工具”，而是嵌入了复杂的责任链条与制度环境。

近年来，政策与监管文件逐渐从一般性“算法透明”诉求转向与风险分级相匹配的差异化要求。例如，EU AI Act 草案对高风险 AI 系统提出了模型可追溯、决策可解释、数据与模型可审计等要求，强调应向不同利益相关方提供可理解的信息。这种规制趋势意味着，高风险 AI 的设计与部署不能只关注预测性能，还必须主动考虑解释性与可审计性的制度性约束。

2.2 可解释性概念与 Linardatos 等的分类

关于“可解释性”(interpretability/explainability)的定义,尚无统一共识。较为常用的工作定义指出,可解释性是指人类能够在多大程度上理解模型内部机制或特定输出的成因²。Linardatos 等人³对现有方法进行了系统梳理,提供了几个重要划分维度。

首先,区分内在可解释模型与后置解释方法。前者如线性模型、决策树和广义加性模型(GAM)等,其结构本身对人类透明,解释源自模型本身;后者则在任意黑箱模型训练完成后,对其输出进行近似解释,如 LIME⁶、SHAP⁷、Integrated Gradients⁸、Grad-CAM⁹等。

其次,区分模型依赖与模型无关方法。模型无关方法只把模型视作输入到输出的映射,不利用内部参数和梯度信息,因而具有广泛适用性;模型依赖方法则可利用梯度、特征重要性等信息,往往在特定架构上具有更强的表达能力。

第三,可区分局部与全局解释。局部方法试图解释单个预测结果或局部邻域,例如 LIME¹⁰与 SHAP¹¹生成的实例级特征重要性;全局方法则试图概括整体决策边界,如决策规则提取、代理模型以及特征整体重要性排序等³。

2.3 原型学习与结构可解释模型

与主要依赖后置解释的黑箱模型不同,原型学习方法试图在模型结构层面融入可解释性约束。其基本思想是学习一组具有语义意义的“原型”(prototypes),并通过输入与这些原型的相似性来进行分类或回归,从而形成“这个样本之所以被判为 A,是因为它与这些 A 类原型相似,并与这些 B 类原型相异”的决策逻辑,这种逻辑与人类基于相似案例进行推理的方式高度相似。

ProtoPNet⁴在卷积神经网络主体上添加一个原型层,通过在特征空间中学习若干可视化原型,并利用原型与输入局部特征的距离实现分类;Neural Prototype Trees⁵进一步以树状结构组织原型,使模型决策可被解释为一条由原型节点构成的路径;ProtoPShare¹²则通过原型共享机制提升解释的简洁性和可重用性。

这类结构可解释模型研究与传统后置解释方法之间并非简单替代关系,而是对“在何种程度上可解释性可以内嵌在表示学习过程中”的探索,为在高风险应用中同时追求性能和可解释性提供了有价值的范式。

3 高风险场景中的解释性需求三维框架

为了系统刻画高风险领域中可解释性的必要性及其差异化形态,本文提出一个“解释性需求三维框架”。该框架由风险类型、责任结构与用户角色三个相互关联的维度构成,旨在回答三个问题:(1)哪些风险需要通过解释性加以缓解;(2)解释性如何嵌入责任分配与追溯机制;(3)不同用户究竟需要何种形式和粒度的解释。

3.1 风险类型维度

在高风险场景中,模型部署所面临的关键风险并不仅限于预测精度不足,还包括一系列与不透明性高度相关的系统性风险。

其一是隐藏偏差与不公正风险。训练数据常包含历史偏见、选择偏差或代理变量,例如在信用评分数据中,邮政编码可能作为种族或收入水平的代理变量,如果模型在决策过程中大量倚赖这些

变量，会在不知不觉中重现甚至放大历史不公。缺乏可解释性时，这种结构性偏差难以及时显现，也不易被领域专家识别与纠正。

其二是分布漂移与外推失效风险。医疗场景中影像设备更新、患者人群结构变化，金融场景中的市场制度变迁和宏观环境波动，都会导致输入分布发生漂移。当模型预测错误无法与其所依赖的特征模式建立可解释联系时，难以判断错误究竟是偶然噪声还是结构性失效，从而延误模型重训和策略调整。

其三是安全攻击与对抗操控风险。对抗样本研究表明，深度网络可能对肉眼难以察觉的扰动高度敏感。一旦攻击者能够推断模型的脆弱维度，则可以通过微小修改实现对高风险系统的操控。缺乏可解释性会削弱防御者发现异常决策模式的能力，使攻击更隐蔽、更难追溯。

其四是错误不可纠正风险。在医疗和金融场景中，领域专家通常希望在 AI 输出基础上进行“有依据的修正”。如果模型不可解释，专家无法判断何时应相信模型、何时应持保留态度，更无法定位影响决策的关键因素，从而将 AI 从“可监督助手”降级为“不可控黑箱”，要么被过度信任，要么被完全弃用。

综观上述风险，可以发现可解释性既是暴露和诊断模型失效模式的工具，也是实现持续监控和稳健部署的前提条件。

3.2 责任结构维度

医疗、金融和司法等高风险领域具有复杂的责任链条。以医疗诊断辅助系统为例，责任主体至少包括模型开发者、医疗机构、临床医生、设备提供方和监管部门；在自动信贷审批系统中，则包括模型开发团队、金融机构管理层、一线审核人员和外部监管者。在发生错误决策或严重损害时，责任如何界定、证据如何获取，很大程度上取决于模型是否提供了可追溯的决策依据。

可解释性在责任结构中至少发挥三类功能。第一，支持事后责任追溯。当出现严重误判时，可解释模型或具有审计日志的后置解释机制可以帮助调查模型在决策时主要依赖了哪些信息，从而判断是否存在数据偏差、算法缺陷或不当使用等问题。第二，促进前瞻性风险治理。监管机构可以基于可解释性工具审查模型是否过分依赖敏感特征或具有明显不合理模式，在大规模推广之前及时干预。第三，支撑制度设计与行业标准。只有当解释具备一定的形式化与稳定性，才能被纳入技术规范 and 合规标准，从而形成可操作的行业监管基础。

因此，在高风险场景中，可解释性不只是技术特性，而是责任分配与治理体系能否有效运转的关键一环。缺乏可解释性的黑箱模型天然弱化了责任可追溯性，增加了“责任真空”与“问责不公”的概率。

3.3 用户角色维度

不同用户对解释的需求在内容、形式和粒度上存在显著差异，这一点在 Linardatos 等人³ 讨论的“用户导向评价维度”中已有初步体现，但在高风险场景中尤为突出。整体而言，可以区分至少四类典型角色：

首先是领域专业人士，如临床医生和金融风险控制人员。他们通常具备较强的知识背景，希望通过解释来判断模型输出与领域知识是否一致，形成“人机共识”或“有依据的分歧”。对这类用户而言，局部解释（例如医疗影像中的病灶定位、信贷模型中的特征贡献）尤为关键，且需要与专业术语和既有诊疗/风控流程紧密对接。

其次是系统开发者与机器学习工程师。他们需要的是能够暴露模型缺陷和失效模式的解释，以指导特征工程、模型选择和安全加固。对该群体而言，高保真度与稳定性是首要要求，解释形式可以较为技术化，如特征重要性排序、表示空间可视化和影响函数分析等。

第三是终端用户与受影响群体，如患者和信贷申请人。他们的解释需求更偏向“可感知的理由”，例如“哪些因素导致了我的贷款被拒绝”，并期望由此获得可操作的建议。这里的解释需要简洁、通俗，并避免技术术语，但同时又要足以支撑其权利主张和申诉渠道。

第四是监管与审计机构。这类主体更关注模型整体行为是否符合法律法规与伦理原则，因而既需要全局行为的统计性说明，如公平性指标和错误分布，也需要可抽样审查的局部解释，便于执行具体案件的合规审查。

在高风险场景中，单一形式或单一层级的解释通常无法同时满足上述多类角色的需求。因此，真正可用的解释性应当被视作一种系统属性而非单一模型属性，需要通过多视角、多粒度的解释机制协同实现。这也说明，在此类场景下构建“一个模型——一种解释”的思路是远远不够的。

4 黑箱模型在高风险领域的风险机制

在上述三维框架下，可以更加具体地刻画黑箱模型在高风险场景中所带来的复合风险。这里的“黑箱”不仅指模型内部参数难以解读，也包括缺乏可靠后置解释或审计机制的系统。

首先，在风险类型维度，黑箱模型强化了隐藏偏差和分布漂移的不可见性。在医疗领域，若图像分类网络实质上更多依赖背景纹理、标记条形码等伪特征，而非病灶本身，则模型在特定数据集上表现良好，却在跨机构部署时灾难性失效。类似现象在金融风控中也曾出现，如模型过度依赖申请渠道或地理区域等易变因素，一旦宏观环境变化即迅速失效。如果不具备对模型内部决策逻辑进行可视化或因果分析的能力，这类问题往往要在发生大量错误决策后才能被发现。

其次，在责任结构维度，黑箱模型削弱了各方履责的能力。临床医生在使用不可解释的辅助诊断系统时，一方面难以根据模型输出判断诊断策略是否应当调整，另一方面在诊疗纠纷中也难以证明其对模型输出进行了有效审查。金融机构在采用黑箱信贷模型时，一旦遭遇“自动化歧视”指控，往往难以提供可用于证明“善意使用”和“合规设计”的证据。即便技术团队出具一些后置解释结果，如果这些结果的稳定性和保真度无法被独立验证，其在责任分配中的证据价值也十分有限。

再次，在用户角色维度，黑箱模型对不同用户的信任关系产生复杂影响。一部分专业人士可能由于缺乏时间和技术背景而倾向于过度信任模型输出，将其视为“更客观”的决策来源；另一部分用户则因完全无法理解模型而选择拒绝使用或仅形式上“调用”而实际忽略其结果。这两种极端都偏离了“人机协同”的理想状态。对于终端用户而言，黑箱模型容易被视作无法沟通的权力结构，从而加剧对自动化系统的不信任和抵触。

Ghorbani 等人¹³ 进一步表明，即便引入后置可视化解释，如果解释本身对输入扰动与模型修改高度敏感，则其在高风险场景下可能产生虚假安全感：用户误以为自己理解了模型，而实际上解释仅是脆弱近似。综合上述因素，黑箱模型在高风险场景中不仅是技术不透明的问题，更构成伦理、法律与社会信任的系统性隐患。

5 可解释人工智能的技术路径：从透明模型到原型学习

在充分认识高风险场景对解释性的刚性需求后，有必要在现有可解释人工智能方法谱系中，系统比较不同技术路径的适用性与局限性。

5.1 内在可解释模型

内在可解释模型的典型代表包括线性回归¹⁴、逻辑回归¹⁵、决策树¹⁶和广义加性模型 (GAM)¹⁷等。这类模型的共同特点是其决策结构本身对人类透明，参数具有较明确的语义，如特征权重或决策路径。对于结构化、低维特征的传统风险评估任务，如部分信贷评分和医疗评分量表，这些模型长期被广泛采用。

Caruana 等人¹⁸展示了可解释加性模型在预测肺炎死亡风险和再入院风险中的应用，证明在适当设计下，内在可解释模型可以在保持高度透明的同时达到接近甚至优于复杂黑箱模型的性能。这一结果在医疗界产生了重要影响，说明在某些高风险任务中，“简单而透明”的模型并非必然牺牲性能。

然而，内在可解释模型在处理高维、非线性和多模态数据（如医学影像和自由文本病历）时能力有限，难以捕捉复杂空间和语义结构。即便通过特征扩展和高阶交互项提升表达能力，模型也容易变得难以理解，从而失去“内在可解释”的优势。在许多高风险任务中，完全依赖这类模型难以满足性能要求，这推动了后置解释和结构可解释神经网络方法的发展。

5.2 后置解释方法

后置解释方法在任意给定的黑箱模型之上工作，不改变其内部结构，而是通过局部线性近似、特征扰动分析或梯度可视化等方式，试图解释模型的输出。LIME⁶通过在目标实例附近采样并训练局部线性模型，给出该实例各特征的局部重要性；SHAP⁷则基于 Shapley 值理论，为每个特征分配对预测贡献的公平“分摊值”，在理论上统一了多种重要性度量方法。Grad-CAM 等可视化方法则利用梯度信息生成热力图，直观展示图像中哪些区域对模型预测最为关键。

这类方法的优势在于通用性强、易于集成，即便面对复杂的深度网络和已有部署系统，也可以后置嵌入解释层。然而，大量研究指出，它们在高风险场景中存在三个关键问题：一是保真度有限。局部线性近似或特征扰动方法仅在小邻域内拟合复杂决策边界，难以保证解释与模型真实内部机制的一致性；二是稳定性不足。¹³表明，微小输入扰动即可导致解释结果发生巨大变化，即“可解释性是脆弱的”；三是易受滥用与误读。当用户缺乏足够技术背景时，可能将后置解释误认为对模型机制的“真实揭示”，从而在错误的理解基础上做出关键决策。

因此，在高风险领域，后置解释可以作为辅助工具，用于调试模型、初步审查偏差或为终端用户提供粗粒度说明，但难以单独承担责任追溯和合规审计的重任。其更合理的定位是与结构可解释模型和制度性保障相结合，共同构建多层次解释体系。

5.3 结构可解释模型与原型学习

结构可解释模型试图在模型设计阶段引入可解释性约束，使内部表示或中间输出直接对应于人类可理解的概念或原型。概念瓶颈模型 (Concept Bottleneck Models, CBM)¹⁹是典型例子，其通过在网络中间设置概念层，强制模型首先预测一组人类可理解的概念（如“肿块边界不规则”“钙化斑块存在”等），再根据这些概念做最终预测。这种结构使得领域专家能够直接检查和校正中间概念，从而实现“对解释进行干预”的能力。

原型学习则是另一类重要的结构可解释范式。ProtoPNet⁴提出 *this looks like that* 的思想，在卷积特征空间中学习若干原型，每个原型对应训练集中某一局部图像区域。测试时，模型通过比较输入与各原型的局部相似性作出分类决策，并在图像上高亮与某些原型匹配的区域，从而给出直观

解释：“该病灶被判为恶性，是因为它与这些恶性原型相似，并与这些良性原型相异”。在皮肤病和胸部 X 线等任务上，ProtoPNet 在保持接近基线 CNN 性能的同时，提供了符合临床思维习惯的案例式解释。

Neural Prototype Trees⁵ 通过构建树形结构，使每个内部节点关联若干原型，叶节点对应具体类别，模型预测自然对应一条原型路径，兼具树模型的全局可理解结构与原型方法的局部可视化优势。ProtoPShare¹² 引入原型共享机制，减少冗余原型，提高解释的紧凑性和可维护性。也有工作将原型学习扩展至医学影像分割、多标签诊断和功能磁共振成像（fMRI）分析等场景，探索原型在不同模态下的语义稳定性。

相较于传统后置解释方法，原型学习提供的解释更紧密地与模型结构和训练目标绑定，因而在忠实度和可审计性上具有天然优势。但其也存在挑战：如何保证原型捕获的是“语义概念”而非伪相关纹理，如何在保持高性能的同时限制原型数量以维持可理解性，如何度量不同用户对原型解释的认知负担等。在高风险场景中，这些问题尤为关键，需要结合领域知识和用户研究加以解决。

综合来看，内在可解释模型、后置解释方法和结构可解释模型构成了 XAI 技术谱系的三个主要支柱。对于高风险领域而言，更加可行的路径不是简单选取其一，而是基于具体任务和用户需求，设计多层次、混合式的解释架构：在可行时优先采用内在可解释模型，在复杂模态上引入结构可解释深度网络，并辅以后置解释进行调试与补充。

6 现实部署中的挑战与潜在解决路径

尽管 XAI 技术取得了快速进展，在实际高风险系统中实现“有效且负责任的可解释性”仍面临多重挑战。这些挑战既源于技术本身的局限，也与制度环境和人机交互条件密切相关。

6.1 性能与可解释性的结构性张力

在许多任务中，更复杂的模型往往能取得更高的预测性能，而可解释性要求倾向于限制模型复杂度或引入额外约束。这种张力在高风险场景尤为突出：性能直接关系到生命与财产安全，可解释性则关系到责任与信任，二者都难以被简单牺牲。

一种潜在解决思路是采用分层架构和任务分解。在患者筛查等需要高召回率的任务中，可以允许前端使用高性能黑箱模型进行初筛，但在决策链条的关键节点（如最终诊断或高额授信）则引入更为可解释的模型或结构化审查流程，确保最关键的决策环节在可解释和可审计的前提下进行。另外，也有研究显示，通过合理设计结构可解释模型（如 NAM、CBM 和原型网络），在许多任务上性能损失可以控制在可接受范围内，这提示我们不应过早假定“高性能必然不可解释”。

6.2 解释方法的稳定性与验证难题

Ghorbani 等人¹³ 提出的“解释脆弱性”问题表明，许多后置解释方法对输入扰动和模型微调高度敏感，这在高风险场景中是难以接受的。即便是结构可解释模型，也可能在不同训练轮次或数据子集上学到语义不稳定的原型和概念。如何系统评估和提升解释的稳定性，仍是开放难题。

一方面，需要发展解释一致性度量，例如在不同重采样、初始化或轻微扰动条件下，比较解释结果的一致性分布，以此作为解释可靠性的定量指标。另一方面，可考虑引入不确定性表达机制，即为解释本身提供置信区间或稳定性评分，提醒用户在解释高度不稳定时谨慎采信。在高风险场景下，缺乏稳定性的解释应视为“不合格解释”，其使用应受到严格限制。

6.3 语义一致性与人类概念对齐

原型学习和概念瓶颈等结构可解释方法在形式上提供了清晰的结构，但这并不自动保证其语义与人类概念一致。原型可能捕获的是数据集中频繁出现的纹理或标记，而非真正的病理结构；概念预测层可能通过利用相关但非因果的特征完成任务，从而得到“看似合理但实则伪相关”的概念解释。

要缓解这一问题，一方面可以在训练过程中引入人类参与的监督，例如让专家对部分原型进行标注和筛选，移除明显与目标概念不符的原型，鼓励模型学习医学上有意义的模式；另一方面，可以结合因果推断与不变性学习思想，对原型和概念进行跨分布稳定性检验，仅保留在不同数据来源和采集条件下均保持稳定的模式，作为高置信度解释的候选。

6.4 多角色异质化需求与系统级设计

正如前文所述，不同用户角色对解释的形式和粒度有着截然不同的需求。在实践中，如果解释系统只为其中一类用户优化，往往会使其他用户难以使用或误解解释信息。在高风险场景中，解释系统需要在模型层面、界面层面和制度层面进行系统设计。

在模型层面，可以采用“多头输出”或“多级表示”的结构，同时生成面向专家的细粒度解释（如原型匹配与特征贡献）和面向终端用户的粗粒度解释（如主要影响因素和可行改进建议）。在界面层面，应采用分层展示策略，允许用户在简要解释与详细技术信息之间自主切换。在制度层面，需通过行业指南和标准明确不同类型决策必须提供的最小解释集合，如对金融拒贷决策，至少应列出若干可操作的主要影响因素及其方向，并提供申诉渠道。

6.5 评价体系与监管框架的缺失

目前，对可解释性的评价大多停留在研究型数据集和用户调研层面，缺乏可直接用于监管和合规审查的统一指标体系。不同方法论文中使用的评价维度和实验设置差异巨大，给横向比较和工程选型带来困难。

未来需要在忠实度、稳定性和可理解性指标基础上，发展更加贴近高风险实践的任务导向评价框架。例如，可以设计“带解释的诊断决策模拟”实验，评估在不同解释条件下医生的决策质量变化；或在信贷审批模拟中比较不同解释策略对申请人行为和违约率的长期影响。这类实验结果可以为监管机构制定“最低可解释性要求”和“解释充分性标准”提供证据基础。

7 结论与展望

本文在系统梳理可解释人工智能研究进展的基础上，针对医疗和金融等高风险领域提出了一个“风险类型—责任结构—用户角色”的解释性需求三维框架。基于该框架，我们论证了在高风险场景中，可解释性不是锦上添花的附加属性，而是关系到错误诊断、责任追溯、公平正义和社会信任的基础约束。缺乏可解释性的黑箱模型将放大隐藏偏差、分布漂移和安全攻击的后果，削弱责任机制的有效性，并破坏不同用户群体之间的信任关系。

在技术层面，本文将可解释性方法划分为内在可解释模型、后置解释方法和结构可解释模型三类，并重点分析了结构可解释模型在高风险场景中的潜力与挑战。原型学习以其贴近人类“以例证说理”的思维方式，在医疗影像等任务中展现出优越的认知契合度，是连接深度表示学习与人类可理解性的有前景路径。

然而，要在真实高风险系统中实现“可解释且可用”的 AI，仍需在多个方面持续推进：（1）发展混合式架构与任务分解策略，在关键决策节点优先使用结构可解释模型或可审计流程；（2）建立解释稳定性与一致性的系统性评价方法，将解释本身的不确定性显性化；（3）通过人机协同与因果不变性学习，提升原型和概念表示的语义一致性；（4）面向不同用户角色设计多层次解释系统，实现解释信息在技术层面与制度层面的协同；（5）在监管与行业标准制定中引入可解释性评价指标，推动从“原则宣示”走向“操作化要求”。

随着高风险领域对 AI 依赖程度的不断提高，可解释性研究势必从方法层面的“算法新招”转向系统层面的“工程与治理结合”。原型学习和其他结构可解释模型提供了重要的技术抓手，而如何将这些技术嵌入具体的医疗与金融工作流，并与法律、伦理和组织实践形成良性互动，将是未来一段时间内值得重点关注的跨学科研究方向。

参考文献

- [1] Lilian Edwards. “The EU AI Act: a summary of its significance and scope”. In: *Artificial Intelligence (the EU AI Act)* 1 (2021), p. 25.
- [2] Finale Doshi-Velez and Been Kim. “Towards a rigorous science of interpretable machine learning”. In: *arXiv preprint arXiv:1702.08608* (2017).
- [3] Pantelis Linardatos, Vasilis Papastefanopoulos, and Sotiris Kotsiantis. “Explainable ai: A review of machine learning interpretability methods”. In: *Entropy* 23.1 (2020), p. 18.
- [4] Chaofan Chen et al. “This looks like that: deep learning for interpretable image recognition”. In: *Advances in neural information processing systems* 32 (2019).
- [5] Meike Nauta, Ron Van Bree, and Christin Seifert. “Neural prototype trees for interpretable fine-grained image recognition”. In: *Proceedings of the IEEE/CVF conference on computer vision and pattern recognition*. 2021, pp. 14933–14943.
- [6] Marco Tulio Ribeiro, Sameer Singh, and Carlos Guestrin. “” Why should i trust you?” Explaining the predictions of any classifier”. In: *Proceedings of the 22nd ACM SIGKDD international conference on knowledge discovery and data mining*. 2016, pp. 1135–1144.
- [7] Scott M Lundberg and Su-In Lee. “A unified approach to interpreting model predictions”. In: *Advances in neural information processing systems* 30 (2017).
- [8] Andrei Kapishnikov et al. “Guided integrated gradients: An adaptive path method for removing noise”. In: *Proceedings of the IEEE/CVF conference on computer vision and pattern recognition*. 2021, pp. 5050–5058.
- [9] Ramprasaath R Selvaraju et al. “Grad-cam: Visual explanations from deep networks via gradient-based localization”. In: *Proceedings of the IEEE international conference on computer vision*. 2017, pp. 618–626.
- [10] Damien Garreau and Ulrike Luxburg. “Explaining the explainer: A first theoretical analysis of LIME”. In: *International conference on artificial intelligence and statistics*. PMLR. 2020, pp. 1287–1296.
- [11] Guy Van den Broeck et al. “On the tractability of SHAP explanations”. In: *Journal of Artificial Intelligence Research* 74 (2022), pp. 851–886.
- [12] Dawid Rymarczyk et al. “Protopshare: Prototypical parts sharing for similarity discovery in interpretable image classification”. In: *Proceedings of the 27th ACM SIGKDD Conference on Knowledge Discovery & Data Mining*. 2021, pp. 1420–1430.
- [13] Amirata Ghorbani, Abubakar Abid, and James Zou. “Interpretation of neural networks is fragile”. In: *Proceedings of the AAAI conference on artificial intelligence*. Vol. 33. 01. 2019, pp. 3681–3688.
- [14] Xiaogang Su, Xin Yan, and Chih-Ling Tsai. “Linear regression”. In: *Wiley Interdisciplinary Reviews: Computational Statistics* 4.3 (2012), pp. 275–294.
- [15] Michael P LaValley. “Logistic regression”. In: *Circulation* 117.18 (2008), pp. 2395–2399.

- [16] Yan-Yan Song and Ying Lu. “Decision tree methods: applications for classification and prediction”. In: *Shanghai archives of psychiatry* (2015).
- [17] Trevor J Hastie. “Generalized additive models”. In: *Statistical models in S* (2017), pp. 249–307.
- [18] Rich Caruana et al. “Intelligible models for healthcare: Predicting pneumonia risk and hospital 30-day readmission”. In: *Proceedings of the 21th ACM SIGKDD international conference on knowledge discovery and data mining*. 2015, pp. 1721–1730.
- [19] Pang Wei Koh et al. “Concept bottleneck models”. In: *International conference on machine learning*. PMLR. 2020, pp. 5338–5348.