



安徽大學
人工智能學院
School of Artificial Intelligence
Anhui University

《计算机视觉实验》大作业

显式与隐式表示在人工智能驱动的放射学影像 3D 重建中的应用

学 院: 人工智能学院

专 业: 人工智能

学 生: 杨跃浙 WA2214014

指导老师: 张鹏

课程编号: ZH52406

课程学分: 2

提交日期: 25.06.20

Abstract

The demand for high-quality medical imaging in clinical practice and assisted diagnosis has made 3D reconstruction in radiological imaging a key research focus. Artificial intelligence (AI) has emerged as a promising approach to enhancing reconstruction accuracy while reducing acquisition and processing time, thereby minimizing patient radiation exposure and discomfort and ultimately benefiting clinical diagnosis. This review explores state-of-the-art AI-based 3D reconstruction algorithms in radiological imaging, categorizing them into explicit and implicit approaches based on their underlying principles. Explicit methods include slice-based, volume-based, and Gaussian representations, while implicit methods encompass implicit prior embedding and neural radiance fields. Additionally, we examine commonly used evaluation metrics and benchmark datasets. Finally, we discuss the current state of development, key challenges, and future research directions in this evolving field. Our project available on: <https://github.com/Bean-Young/AI4Radiology>.

Keywords

Radiological Imaging; 3D Reconstruction; Artificial Intelligence.

摘 要

临床实践和辅助诊断对高质量医学成像的需求，使放射学成像中的三维重建成为一个关键的研究重点。人工智能已成为提升重建精度并减少采集与处理时间的有前景的方法，从而最大程度地减少患者的辐射暴露和不适，并最终有助于临床诊断的发展。本文综述了放射成像中最先进的基于人工智能的三维重建算法，并根据其基本原理将其分为显式方法和隐式方法。显式方法包括基于切片、体素和高斯表示；隐式方法则包括隐式先验嵌入（implicit prior embedding）和神经辐射场（neural radiance fields）。此外，我们还回顾了常用的评估指标和基准数据集。最后，本文讨论了该领域当前的发展状况、主要挑战以及未来的研究方向。我们的项目地址：<https://github.com/Bean-Young/AI4Radiology>。

关键词

放射成像；三维重建；人工智能。

目 录

1	引言	4
1.1	重建算法的发展	4
1.2	神经网络的兴起	4
1.3	生成模型的兴起	5
1.4	新型表示方法的出现	5
2	方法	7
2.1	文献综述	7
2.2	文献分类	7
3	数据集与评估指标	9
3.1	数据集	9
3.2	评估指标	9
4	显式重建方法	10
4.1	基于切片的表示	11
4.2	基于体素的表示	11
4.3	高斯表示	13
5	隐式重建方法	13
5.1	隐式先验嵌入	13
5.2	神经辐射场	14
6	讨论与挑战	15
6.1	重建表示方法的比较	15
6.2	成像质量评估	16
6.3	效率与有效性	16
6.4	隐私保护	17
6.5	模型可解释性	17
7	结论	17

1 引言

放射学涉及一系列用于获取身体各部位图像的检查方法。多种成像检查手段使医生能够观察人体内部结构，包括 X 射线、MRI（磁共振成像）、超声、CT 扫描和 PET 扫描（正电子发射断层扫描）[1]。如今，CT、MRI 和 PET 等放射成像模式已被广泛应用于疾病的早期检测、诊断和治疗[2]。为了将各类传感器采集的信号转换为图像，以分析细胞和组织中的生物过程，图像重建算法是必不可少的[3]。在这些算法中，三维重建尤为重要，它能够提供更器官的详细三维图像，有助于发现感染、癌症、外伤以及血管和器官的异常[4]。

此外，放射成像中的三维重建研究位于现代应用数学、工程、医学、放射学和计算机科学的交叉点上[5]。该领域最初发展于基于概率理论的重建算法。随着神经网络和生成模型的出现，该领域取得了前所未有的突破。更近期，一些新的表示范式（representation paradigms）进一步重塑了图像重建的格局。在本文中，我们从四个不同的角度介绍放射成像中三维重建的发展：传统重建算法 1.1，基于神经网络的方法 1.2，生成模型 1.3，以及新兴的表示技术 1.4。需要明确的是，这四个角度并不是彼此孤立的分支，而是在相互影响和跨学科融合中共同演进的。

1.1 重建算法的发展

最初，研究者采用了基于连续表示的重建问题分析方法[6]，使用简单的数学模型将图像转换为三维。例如，CT 中的滤波反投影（Filtered Back Projection, FBP）[7] 和 MRI 中的快速傅里叶变换（Fast Fourier Transform, FFT）[8, 9]。这些算法至今仍被视为基础模型，因为它们在无噪声、充分采样的数据假设下具有较高的计算效率，并能生成高质量图像[10]。然而，这些基于物理驱动的方法通常仅关注成像系统的几何结构和采样特性[11]。虽然计算效率较高，但它们对噪声非常敏感，容易导致重建质量下降。

为了解决这一问题，研究人员发展出了更灵活的重建框架——迭代重建（Iterative Reconstruction, IR）方法[12]。这类方法在处理噪声和不完整数据方面具有更好的鲁棒性，尽管计算开销相对更大[13]。

因此，许多融合数据特征的高度优化算法被提出。其中一个被广泛应用的例子是在 PET 成像中使用的有序子集期望最大化（Ordered Subset Expectation Maximization, OSEM）算法[14, 15, 16]，这是最大似然期望最大化（Maximum Likelihood Expectation Maximization, MLEM）算法的加速版本[17]，可以提升收敛速度和图像质量。OSEM 通过将投影数据划分为若干子集，并逐步更新模型，从而提高了收敛速度和计算效率。然而，这类传统算法在建模复杂解剖结构和噪声模式方面存在局限，其性能在很大程度上依赖于高质量的扫描数据，而这在临床环境中可能具有一定的随机性[18]。

1.2 神经网络的兴起

幸运的是，近年来，人工智能（AI）因其卓越的代表能力和三维建模能力而受到广泛关注[19]，由此引发了研究热潮。因此，AI 在放射成像三维重建中的应用正获得前所未有的公众关注[20, 21]。

在 AI 应用的早期，卷积神经网络（Convolutional Neural Networks, CNNs）[22] 展现出强大的复杂表示学习能力[23]。与此同时，众多方法开始采用 CNN 来实现三维放射图像的重建[24]。Gong 等人将深度残差 CNN 集成到迭代重建框架中，借助患者间的信息提升了 PET 图像的质量[25]。然而，CNN 对位置信息的敏感性较差，且难以捕捉全局上下文[26]，从而限制了其在医学图像重建任

务中的应用。受 Transformer 架构 [27] 的启发, 视觉 Transformer (Vision Transformers, ViT) [28] 的引入有效缓解了上述问题, 成为医学图像分析领域的新基准 [29]。

然而, ViT 主要设计用于特征提取, 直接应用于重建任务仍存在困难 [30]。此外, ViT 的自注意力机制在处理高分辨率和复杂医学图像时计算开销较大, 可能带来效率问题 [30]。

1.3 生成模型的兴起

与前述方法形成鲜明对比的是, 生成建模 (generative modeling) 的进展在另一个方向上提供了替代性的解决方案。其中一种方法是变分自编码器 (Variational Autoencoder, VAE) [31], 它通过逼近数据分布来学习概率潜在空间, 从而生成新的数据样本。与此同时, 生成对抗网络 (Generative Adversarial Networks, GAN) [32] 于 2014 年首次提出, 其通过两个神经网络之间的对抗训练以生成逼真的数据样本。GAN 在生成任务中表现出色, 在放射成像的三维重建中引起了广泛关注 [6]。Luo 等人将 GAN 与 CNN 和 ViT 结合, 提出了 Transformer-GAN 框架, 用于从低剂量 PET 图像重建高质量的标准剂量 PET 图像, 取得了优异的效果 [33]。

尽管 GAN 在提升图像清晰度和细节方面表现出强大能力, 其训练过程中固有的不稳定性可能会产生不自然的伪影 (artifacts) [34], 这在医学成像应用中是不可忽视的问题。相比之下, 扩散模型 (diffusion models) 采用基于噪声的框架, 逐步向数据中添加噪声直至其变为完全随机 [35], 然后通过学习反向过程迭代去噪, 恢复原始数据并生成新的样本。这一框架通常具有更好的训练稳定性, 使扩散模型成为放射成像三维重建中的一种有前景的新方案 [36]。例如, AdaDiff 引入了自适应扩散先验, 用于加速 MRI 重建, 能够应对成像算子和 MRI 图像分布中出现的领域偏移问题 [37]。

然而, 扩散模型在处理多视角一致性方面仍存在困难 [38]。其高计算复杂度以及直接生成三维模型的挑战, 常导致三维医学成像的效果不尽理想。这类显式生成方法往往无法充分表现内部细节, 且难以解决视角一致性问题 [39]。

1.4 新型表示方法的出现

2020 年, 神经辐射场 (Neural Radiance Fields, NeRF) 在自然图像领域的新视角合成任务中引起了广泛关注, 使隐式生成模型成为一种可行的解决方案 [40]。例如, MedNeRF 将 NeRF 与 GAN 结合, 用于从单视角或少量视角的 X 射线图像中重建具备三维感知能力的 CT 投影图像 [41]。该网络在保持高保真解剖结构表示的同时, 显著降低了患者对电离辐射的暴露, 有助于医学应用。

尽管 NeRF 在实现三维场景的空间一致性重建方面表现出色, 但其渲染速度较慢, 使其不适合放射医学中的实时成像需求 [42]。2023 年, 三维高斯投影 (3D Gaussian Splatting, 3DGS) 框架被提出, 作为自然图像中新视角合成的一种显式辐射场方法 [43]。该框架在实现高精度的同时, 还支持实时图像渲染 [44], 为其在医学成像领域的应用奠定了基础。例如, R^2 -Gaussian 是一种创新的三维高斯投影框架, 专为稀疏视角层析重建优化, 有效解决了积分偏差问题 [45]。该方法在保证体积成像精度的同时, 显著降低了计算时间。

总的来说, 过去几十年中, 人工智能的进步极大地推动了放射成像三维重建的发展, 催生了多种创新性方法。图1展示了该领域的发展历程。因此, 有必要对现有研究成果进行总结, 并对各类方法进行系统的比较与分析, 为后续研究提供参考。

然而, 现有的综述往往聚焦于特定模型, 或仅总结部分技术, 常常忽略了隐式成像方法 [46, 6,




图 1: 文献中关于放射图像重建技术发展的简要时间线。

47, 48]。这种狭隘的视角使读者难以全面理解放射成像与计算机科学的融合及其技术演进。本文综述旨在全面回顾人工智能在放射成像三维重建中的应用，涵盖显式重建与隐式重建两大类方法。两种方法的区别见图2。本文收集了过去五年内的相关文献，深入探讨了该领域的关键挑战与应对策略，为研究人员提供可靠的参考。综述内容覆盖了多种放射成像模态，包括三维超声、CT、MRI、PET 和 SPECT。基于当前研究中的核心问题，本文对现有方法进行了全面总结，主要贡献如下：

- 涵盖多个解剖区域的放射成像任务，系统总结了该领域最常见的基于人工智能的三维重建方法；
- 从医学图像与计算机图形学融合的视角出发，将现有方法划分为显式重建与隐式重建两类；这也是首个系统性纳入隐式重建方法的综述；
- 总结并整理了 29 个公开可用的数据集，是当前综述中涵盖规模最大的；
- 提出该领域未来的研究方向。

本综述其余部分的结构如下：第2节介绍文献调研方法；第3节总结公开数据集与评估指标；第4节回顾显式重建方法在三维放射成像中的应用；第5节重点介绍隐式重建方法的应用；第6节探讨不同三维重建表示方法的优劣，并分析当前的挑战与未来研究方向；最后，第7节对全文进行总结。




图 2: 放射成像中五种不同的重建表示形式，第一行为显式表示，第二行为隐式表示。

2 方法

2.1 文献综述

本研究关于放射成像三维重建与人工智能的相关文献主要来源于以下数据库：Web of Science¹、Google Scholar² 和 Scopus³，检索范围涵盖近五年的发表文献。

首先，我们通过文章类型和研究领域等筛选条件对检索结果进行初步过滤，以缩小结果范围。随后，去除重复记录。接着，根据标题、摘要和研究筛选标准对文献进行筛查，并排除无法获取的文献。最终，共有 64 篇符合纳入标准的研究被纳入系统性综述。图3展示了系统文献综述的流程图，这些研究按年份的分布情况见图5(a)。

在图3中，我们使用的检索关键词包括“artificial intelligence (人工智能)”、“deep learning (深度学习)”、“3D”、“medical imaging (医学成像)”以及“imaging reconstruction (图像重建)”。仅包含全部这些关键词的研究文章才被纳入本研究中。我们采用以下三项筛选标准：**1)** 研究内容筛选：依据文章本身的研究重点进行筛选，严格评估其相关性，确保所选文献具有代表性且符合研究范围；**2)** 引用量：我们评估每篇文章的引用次数，优先选择引用量较高的文献，因为引用量往往反映其在领域内的认可度和影响力；**3)** 代表性期刊或会议：优先选取发表于权威期刊或顶级会议的论文，如 *IEEE Transactions on Medical Imaging (T-MI)*、*Medical Image Analysis (MedIA)*、*The IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*、*International Conference on Medical Image Computing and Computer Assisted Intervention (MICCAI)* 等，以确保所选文献经过严格的同行评审，具有较高的可信度。

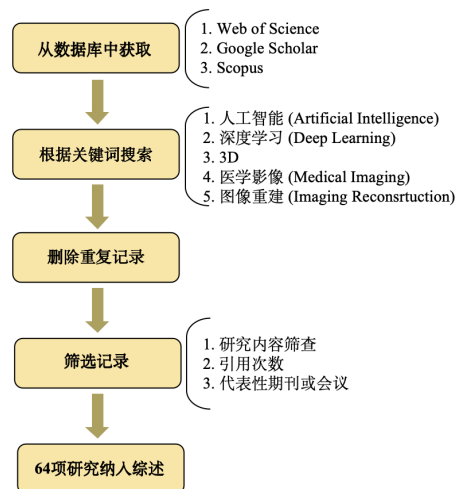


图 3: 文献综述流程图。

2.2 文献分类

关于放射图像三维重建的研究，已有多种可行的分类方式 [46, 49]。一种常见方法是基于成像模式进行分类，根据研究关注的成像方式将其划分为 CT、MRI、PET、SPECT、超声 (US) 或多模态

¹<https://www.webofscience.com/>

²<https://scholar.google.com/>

³<https://www.scopus.com/>

成像，见图5(b)所示。另一种分类方式是根据目标解剖区域进行区分，如聚焦于脑部成像、乳腺成像或全身成像的研究。第三种分类方法则基于重建任务类型进行划分，通常可归纳为三类，如图4所示。**任务 I** 是从原始数据中重建三维图像，主要目的是加快成像过程；**任务 II** 则是将低剂量图像转换为常规剂量图像，旨在提升图像分辨率或减少伪影；**任务 III** 则关注于从缺失信号中重建图像，目标是在视角信息有限的情况下还原完整图像。

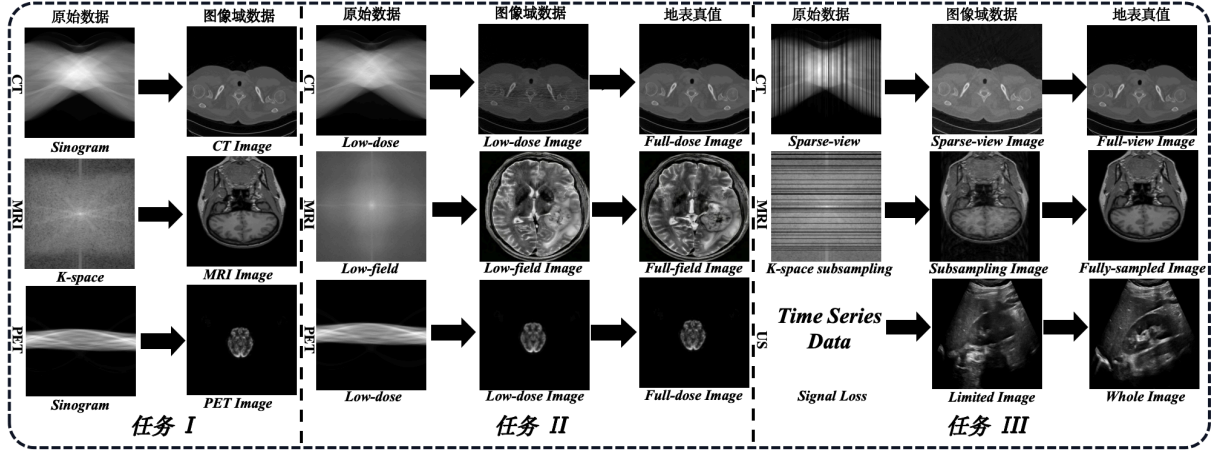


图 4: 放射图像重建中三类典型任务。

尽管这些分类方式在分析方向上具有重要参考价值，但它们未从人工智能的角度考虑方法论层面的差异。在三维表示的语境下，重建方法可进一步划分为显式 (explicit) 和隐式 (implicit) 两类。显式表示采用可直接观察的形式，如点、体素或高斯表示，这些本质上是离散的。特别地，高斯表示在点与点之间保持离散结构的同时，在每个点内部保持连续性。而隐式表示则依赖于连续函数（如神经辐射场）来进行建模，这种方式更具抽象性。基于这一人工智能驱动的视角，我们重新审视医学图像三维重建方法，并根据其输出表示形式将方法划分为显式重建与隐式重建。基于该分类标准的文献分布见图5(c)。在本综述中，我们首次基于表示形式对文献进行创新性分类。




图 5: 综述文献的分类结果，包括：(a) 按成像模态分类，(b) 按发表年份分类，(c) 按重建方法中的表示形式分类。

3 数据集与评估指标

3.1 数据集

在放射成像三维重建任务中，公开数据集扮演着至关重要的角色 [50]。高质量、标准化的数据对于算法的训练、验证与测试具有重要意义。公开数据集为研究人员提供了统一的基准平台，使得在相同条件下可以公平地比较不同方法，从而推动算法的优化与进步 [51]。

与其他医学图像任务不同，三维重建通常需要受试者在可比条件下进行两次扫描，尤其需保持姿势、体位和生理状态的一致性，以获取对应的测试样本与真实值（ground truth）数据。此外，由于涉及患者隐私，医学数据受到严格的法律与伦理限制 [52]，数据采集过程既复杂又昂贵。公开数据集的存在大大降低了数据获取门槛。本文综述整理了当前最为全面的适用于放射成像三维重建任务的公开数据集，涵盖 CT、MRI、PET、超声（US）及多模态数据集，详见表1。

表 1: 用于三维重建放射成像任务的开源数据集

成像模态	数据集	数量	描述
CT	VerSe [53, 54, 55]	355	来自多中心、多探测器的 CT 脊柱数据集，用于椎骨标注和分割。
	LIDC-IDRI [56]	1010	低剂量肺部 CT 数据集，用于肺结节分类、分割和检测。
	COVID-CT-Dataset [57]	216	包含 COVID-19 阳性和阴性病例的 CT 图像数据集。
	Richard et al. [58]	6762	提供胸腔 10 个呼吸相位的体积重建数据。
	KiTS19 [59]	300	包含肾肿瘤及其周围结构的自动语义分割 CT 图像数据集。
	LDCT [60]	299	包含常规剂量和模拟低剂量条件下的 CT 投影数据。
	CTSpine1K [61]	1005	整合多个来源的脊柱 CT 数据集，用于椎骨分割与三维重建。
	MIDRC-RICORD-1B [62]	117	来自 COVID 阴性患者的匿名 CT 数据集。
MRI	Corona-Figueroa et al. [41]	25	来自胸部和膝部 CT 扫描的数字重建 X 线图像（DRR）。
	BraTS [63, 64, 65, 66, 67, 68]	2040	来自神经胶质瘤患者的脑部 MRI 扫描，涵盖 T1、T1 增强、T2 和 T2-FLAIR 四种模态。
	IXI [69]	600	包含 T1、T2、PD 加权图像，以及 MRA 和 DWI 影像的正常人群 MRI 数据集。
	ADNI [70]	8320	纵向收集的临床、影像、遗传和其他生物标志物数据集。
	OASIS-1 [71]	436	横断面研究中涵盖不同年龄阶段和认知状态的 MRI 数据集。
	FastMRI [72, 73]	8470	包含膝关节的 K 空间数据与图像数据，用于加速 MRI 重建的机器学习研究。
	HCP [74]	1200	包含群体平均结构与功能 MRI 数据、功能连接性、ICA 分割等高质量处理结果的数据集。
	Landman et al. [75]	21	包括 MPAGE、FLAIR、DTI、静息态 fMRI、B0 和 B1 场图、ASL、VASO、定量 T1 和 T2 映射以及磁化转移成像等多模态数据。
	dHCP [76]	1056	包含结构、弥散和功能性脑部数据及其分割与皮层表面信息的新生儿脑部数据集。
	MSD [77]	750	多参数 MRI 图像，来自胶质母细胞瘤和低级别胶质瘤患者。
	BreastDM [78]	232	包含良性与恶性乳腺肿瘤病例的 DCE-MRI 图像数据。
	OCMR [79]	377	包含多线圈 K 空间数据及其欠采样心脏动态 MRI 序列。
	SKMTEA [80]	155	集成原始定量膝关节 MRI 数据、图像及组织/病灶注释，用于 MRI 成像全流程研究。
	CMRxRecon2024 [81]	330	包含多对比度 K 空间数据，用于多对比度及随机采样心脏 MRI 重建任务。
PET	UDPET [82]	1447	包含 18F-FDG PET 图像的数据集，用于解决全身 PET 超低剂量成像挑战。
US	Wysocki et al. [83]	18	包含合成肝脏超声图像与带跟踪信息的脊柱模型扫描数据。
	MITEA [84]	134	用于左心室收缩功能与质量定量分析的三维超声标注数据集。
	Papageorgiou et al. [85]	13,108	提供胎儿生长的国际标准数据集，用于准确诊断胎儿发育迟缓。
CT	MMWHS [86]	120	涵盖整个心脏的三维 CT 和 MRI 图像，用于心脏分割任务。
MRI	OASIS-3 [87]	1379	包含正常老化个体与阿尔茨海默病患者的神经影像数据及其处理结果。
PET	μ -RegPro [88]	141	用于前列腺活检、局灶治疗、外科及介入任务的数据集。
US			

3.2 评估指标

评估指标在医学图像重建研究中具有重要意义，它们不仅提供标准化的评价方式，还能指导算法优化与验证其临床适用性。科学、合理设计的指标能够客观评估重建图像的保真度、细节保留能

力与噪声抑制效果，确保模型在不同应用场景中的实用性 [89]。由于不同指标关注图像质量的不同方面，单一指标通常难以全面反映算法性能，因此通常需结合多种指标以获得更加全面、可靠的评估。本文总结了在放射成像三维重建任务中常用的评估指标，见表2所示。

表 2: 放射图像重建常用评估指标

名称	计算公式	功能说明
均方误差 (MSE) ↓	$MSE = \frac{1}{N} \sum_{i=1}^N (x_i - y_i)^2$	衡量像素强度的逐点差异。
均方根误差 (RMSE) ↓	$RMSE = \sqrt{MSE}$	MSE 的平方根。
归一化均方根误差 (NRMSE) ↓	$NRMSE = \frac{\sqrt{MSE}}{\max(x) - \min(x)}$	对不同强度范围进行标准化处理后的误差指标。
峰值信噪比 (PSNR) ↑	$PSNR = 10 \log_{10} \frac{\max(x)^2}{MSE}$	评估图像信号强度与误差的比值。
结构相似性指数 (SSIM) ↑	$SSIM(x, y) = \frac{(2\mu_x\mu_y + C_1)(2\sigma_{xy} + C_2)}{(\mu_x^2 + \mu_y^2 + C_1)(\sigma_x^2 + \sigma_y^2 + C_2)}$	衡量两图像在结构上的相似性，值域在-1 到 1 之间。
感知图像片段相似度 (LPIPS) ↓	$LPIPS(x, y) = \sum_l w_l \cdot \ F_l(x) - F_l(y)\ _2^2$	基于深度学习感知相似度的指标。
平均绝对误差 (MAE) ↓	$MAE = \frac{1}{N} \sum_{i=1}^N x_i - y_i $	衡量像素强度的绝对差异。
特征相似性指数 (FSIM) ↑	$FSIM = \frac{\sum_{x,y} PC_m(x,y) \cdot S_L(x,y) \cdot S_C(x,y)}{\sum_{x,y} PC_m(x,y)}$	融合结构信息进行感知质量评估。
信噪比 (SNR) ↑	$SNR = 10 \log_{10} \frac{\sum_{i=1}^N x_i^2}{\sum_{i=1}^N (x_i - y_i)^2}$	衡量信号相对于噪声的清晰度。
对比噪声比 (CNR) ↑	$CNR = \frac{ \mu_R - \mu_B }{\sigma_B}$	衡量感兴趣区域与背景的对比如。
余弦相似度 (CS) ↑	$CS = \frac{\sum x_i y_i}{\sqrt{\sum x_i^2} \cdot \sqrt{\sum y_i^2}}$	衡量图像特征向量之间的夹角相似性。
计算时间 (Time) ↓	以秒为单位	用于评估计算效率。
渲染速度 (Speed) ↑	每秒帧数 (FPS)	衡量图像渲染的实时性能。
模型参数量 (Para.) ↓	模型参数个数	衡量模型复杂度与体积。

表2中符号的定义如下： x_i 与 y_i 分别表示原始图像与重建图像的像素值或特征向量成分， N 表示总像素数。图像的均值与方差分别为 μ_x 、 μ_y 和 σ_x^2 、 σ_y^2 ， σ_{xy} 为它们的协方差。 $\max(x)$ 与 $\min(x)$ 分别表示图像的最大和最小强度值。常数 C_1 和 C_2 是用于 SSIM 计算的稳定因子。在 LPIPS 中， $F_l(x)$ 和 $F_l(y)$ 表示在第 l 层提取的特征图， w_l 为每层的权重。FSIM 基于相位一致性 $PC_m(x, y)$ 、亮度相似性 $S_L(x, y)$ 与对比度相似性 $S_C(x, y)$ 进行计算。对于 CNR， μ_R 与 μ_B 表示感兴趣区域与背景的平均强度， σ_B 表示背景强度的标准差。

表2综合呈现了医学图像重建中的常用评估指标，可分为四大类：逐像素误差、信号与噪声类、感知与结构相似类，以及计算性能类。像素误差指标如 MSE、RMSE、NRMSE 与 MAE 主要衡量重建图像与参考图像之间的强度差异；PSNR、SNR 和 CNR 等信噪类指标则评估图像清晰度与对比度；SSIM、LPIPS、FSIM 与 CS 属于结构与感知相似类，反映图像的主观与结构质量；Time、Speed 与 Para. 则用于衡量算法在实际应用中的计算效率与可行性。以上指标共同构成了对医学图像重建方法在图像质量、结构保真度与计算成本方面的全面评估体系。

4 显式重建方法

在放射成像的 AI 辅助重建中，显式表示最初被广泛采用。最典型的显式重建方法是基于切片 (slice-based) 的方法，即以单张切片为单位进行实验。这类表示广泛应用于 CT、MRI、PET 和 SPECT 成像中，并具备扩展到多模态的潜力。相关详情见表3。

然而，这种方法忽略了放射图像在纵向上的连续性，容易导致切片间产生严重的伪影或不一致性。随后，体素级的重建方法 (volume-based reconstruction) 逐渐兴起。与切片方法不同，体素表示在每个空间位置引入了三维空间信息，使得图像还原更加准确。该表示适用于所有三维成像模态，包括 CT、MRI、PET、SPECT 及多模态数据，详情见表4。

近年来，一种结合神经辐射场 (Neural Radiance Field) 概念的显式高斯表示 (Gaussian representation) —— 3DGS [43] 引起了广泛关注。凭借其精确的表达能力和高效的重建能力，该方法在

CT 图像重建中得到广泛应用，并被尝试扩展至多模态场景。相关内容详见表5。接下来，我们将从不同视角讨论具有代表性的研究论文。

4.1 基于切片的表示

基于切片的方法通常在单一方向上进行图像重建，早期的深度学习方法主要依赖于基于 CNN 的 U-Net 架构 [90]。Du 等人 [91] 提出一种结合残差学习与跳跃连接的 CNN 模型，有效缓解梯度消失问题，并在 PSNR 和 SSIM 方面优于传统方法。此外，该模型还支持跨模态重建，如从 T1 加权 MRI 训练数据中重建 T2 加权 MRI 图像。

随着 ViT 在计算机视觉领域的兴起 [28]，Shi 等人提出 CTTR [92]，一种基于 Transformer 的稀疏视角 CT 重建方法，有效减少伪影和细节丢失。在极度稀疏的视角下，CTTR 在 PSNR 和 SSIM 上表现优于 CNN 方法。

近年来，状态空间模型 Mamba [93] 因其在序列处理中的高效性受到关注。基于此，MambaMIR [94] 将 Mamba 应用于医学图像重建，利用其线性复杂度、全局感受野及动态加权机制，提出任意遮挡机制（Arbitrary-Masked Mechanism）以适应医学图像任务，并融合蒙特卡洛不确定性估计。实验表明，该方法在 Fast MRI 与稀疏视角 CT 任务中达到了 SOTA 或更优性能。

尽管 Mamba 存在方向性限制，难以同时建模二维图像中的全局与局部依赖关系，近年来 RWKV 模型 [95] 提出 WKV 注意力机制，在保留线性复杂度的同时实现长距离依赖建模。Restore-RWKV [96] 融合 Token Shift 机制增强局部特征捕捉能力，是首个基于 RWKV 的医学图像恢复模型，旨在解决高分辨率图像重建中计算复杂与信息缺失的问题。

基于切片的重建方法的优势在于其良好的通用性，能够适配多种成像模态。随着深度学习模型的发展，该方法将持续向更高效率与更高精度演进。

表 3: 基于切片的放射图像重建相关工作。

模态	论文	年份	描述
CT	CTTR [92]	2022	一种基于 Transformer 的双域稀疏视角 CT 重建模型，利用投影域特征提升图像质量。
	DuDoTrans [97]	2022	利用 Transformer 建模长距离依赖关系，增强投影图像，再结合原始图像重建 CT 图像。
	CoreDiff [98]	2023	一种基于扩散的低剂量 CT 去噪模型，采用保持均值的降质算子和 CLEAR-Net，提升图像质量并减少采样步骤。
MRI	Du et al. [91]	2020	一种使用残差学习与跳跃连接的深度学习模型，用于 3D MRI 图像的超分辨率重建。
	PCNN [99]	2021	使用复数卷积和感知损失的复数神经网络，用于快速重建欠采样 MRI 数据。
	SLATER [100]	2022	提出一种无监督 MRI 重建方法，采用对抗 Transformer 学习 MRI 先验并实现零样本推理。
	Wei et al. [101]	2023	一种无监督深度学习模型，通过形变向量场从 cine-MRI 中实时重建 3D MRI 图像。
PET	MCAD [102]	2024	一种融合低剂量 PET 和临床数据的多模态条件扩散模型，用于高质量 PET 图像重建。
	MEaTransGAN [103]	2024	将 CNN、Transformer 与 GAN 集成，利用低剂量 PET 和 T1-MRI 重建高质量标准剂量 PET 图像。
	Singh et al. [104]	2024	提出使用分数生成模型与 PET-DDS 采样方法的 3D PET 重建框架，提升图像质量和鲁棒性。
SPECT	TPL-CNN [105]	2024	一种基于 GAN 的迭代去噪方法，提升 SPECT 心肌灌注图像的重建质量与对比度。
CT/MRI	MambaMIR [94]	2025	基于 Monte Carlo 任意遮挡机制的 Mamba 模型，提高医学图像重建的全局敏感性与不确定性估计能力。
CT/MRI/PET	Restore-RWKV [96]	2024	基于 RWKV 的重建模型，引入 WKV 注意力与 Token Shift 机制，兼顾高效性与全局建模能力。

4.2 基于体素的表示

体素表示通过大量小体积单元对三维结构进行建模 [106, 107]，可直接处理体数据，实现高保真、细节丰富的放射图像重建。在医学应用中，该方法能够精确刻画人体内复杂的解剖结构。

尽管体素重建方法早期也使用 U-Net 网络生成图像，本节重点讨论更先进的生成模型。

生成对抗网络（GAN）通过生成器与判别器之间的对抗训练，使生成器能够输出逼真、符合真实分布的数据 [32]。

在放射图像重建中，Shaul 等人 [108] 提出一种基于 GAN 的欠采样 MRI 重建方法，在保持图像解剖结构的同时加快成像速度。该方法通过结合保真损失、图像质量损失和对抗损失进行优化，生成更加真实自然的 MRI 图像。

类似地，X2CT-GAN [109] 通过 GAN 将双视角 X 光图像重建为三维 CT 图像，降低了辐射暴露与成本。该方法引入特征融合模块整合多视角信息，在 PSNR 上提升 4dB，并在 SSIM 上优于 CNN 方法。

尽管 GAN 效果优异，但易出现模式崩溃（mode collapse）和训练不稳定问题 [110]。扩散模型（Diffusion models）[111, 112, 113, 114] 基于马尔可夫链与变分推理，通过逐步添加噪声并学习去噪过程实现稳定的生成过程，能更全面覆盖真实数据分布。

Chung 等人提出 DiffusionMBIR [115]，将预训练的二维扩散模型与基于模型的迭代重建方法结合，应用于稀疏视角 CT、有限角度 CT 及压缩感知 MRI。该方法通过将二维扩散先验与三维全变差正则项融合，在数据极端稀疏的情况下仍能实现高质量重建，PSNR 和 SSIM 均优于现有方法。

在 PET 领域，Gong 等人 [116] 提出基于 DDPM 的 PET 图像去噪方法，在反向过程中逐步添加与去除噪声，实现高质量图像重建。结果表明该方法在 PSNR 和 SSIM 上优于 NLM、UNet 和 GAN 等传统方法。

由于体素方法在三维信息表达方面具有高精度 [117, 118]，其被广泛采用。但高计算复杂度也限制了其实时成像能力 [119, 120]。未来研究将继续在快速性与精度之间寻求平衡。

表 4: 基于体素的放射图像重建相关工作。

模态	论文	年份	描述
CT	X2CT-GAN [109]	2019	一种基于 GAN 的模型，从双视角 2D X 光图像重建高分辨率 3D CT 图像，具有特定生成器和联合损失函数。
	DEER [121]	2020	为乳腺 CT 少视角重建设计的高效深度学习模型，图像质量高、模型复杂度低。
	HDNet [122]	2020	一种用于锥束 CT 稀疏视角重建的混合域神经网络，内存开销小，适用于低资源场景。
	Singh et al. [123]	2020	DLR 在低剂量胸部和腹盆 CT 中，优于商业 IR 和 FBP 算法，改善图像质量与病灶检测。
	DLR [124]	2020	在保持噪声纹理和空间分辨率的同时，大幅提升图像质量并减少儿科 CT 的辐射剂量。
	DIOR [125]	2022	将迭代优化与深度残差学习结合，用于有限角度 CT 重建，有效抑制伪影，保留细节。
	FreeSeed [126]	2023	提出频段感知与自引导网络，有效去除伪影、恢复稀疏视角 CT 图像中的细节信息。
	C ² RV [127]	2024	多尺度体素表示结合尺度-视角交叉注意力机制，提升三维特征聚合能力与建模精度。
MRI	Pezzotti et al. [128]	2020	融合领域知识与深度学习的 MRI 重建方法，在 fastMRI 挑战中取得领先成绩。
	EMISR [129]	2020	将超分辨率 CNN 的多个隐藏层与子像素卷积模块结合，提升 MRI 重建效果。
	Shaul et al. [108]	2020	将 U-Net 与 GAN 结合，实现高质量 MRI 重建。
	CINENet [130]	2020	4D 深度重建框架，从单次呼气 MRI 中生成高质量 3D CINE 图像。
	MADGAN [131]	2021	提出用于多序列结构 MRI 中异常检测的 GAN 方法，可重建多层相邻切片图像。
	AUTOMAP [132]	2021	端到端深度网络，用于增强受噪声严重干扰的低场 MRI 图像质量。
	Recon3DMLP [133]	2023	结合小核 CNN 处理低频与大核 MLP 处理高频，提升 MRI 三维重建精度。
	Li et al. [134]	2024	集成多分辨率分析与深度学习的 MRI 超分辨率方法，区别于传统 CNN 结构。
PET	DirectPET [135]	2020	通过引入 Radon 反演层，实现快速、高质量的多切片 PET 图像重建。
	DLE [136]	2022	用于 18F-FDG PET 图像增强的深度学习方法，缩短扫描与重建时间，同时保持精度。
	Deidda1 et al. [137]	2023	提出 PET/SPECT/CT 三模态联合重建方法，提升病灶摄取量定量能力。
	Hashimoto et al. [138]	2023	基于扩散模型，结合形状先验增强拓扑建模能力，实现有限视角下三维图像重建。
	Gong et al. [116]	2024	提出基于 DDPM 的 PET 图像去噪方法，结合 PET 和 MRI 先验提升重建性能。
SPECT	Mostafapour et al. [139]	2022	结合残差网络与 UNet，实现心肌灌注 SPECT 图像的图像域直接衰减校正。
CT/MRI	DiffusionMBIR [115]	2023	将扩散模型与基于模型的迭代重建方法融合，从二维扩散先验高质量重建三维医学图像。

4.3 高斯表示

与其他显式方法不同，高斯表示（Gaussian representation）使用数百万可学习的三维高斯点对三维场景进行建模，支持通过可微渲染（differentiable rendering）实现高编辑性和实时医学图像渲染 [140]。

X-Gaussian 首次将 3DGS 引入医学图像领域，通过取消视角依赖性并引入角度-姿态立方初始化策略，实现 PSNR 提升 6.5dB，推理速度提高 73 倍，训练时间缩短 85% [141]。DDGS-CT 进一步提升精度，采用各向异性建模策略及双重采样机制，在 PSNR 和 SSIM 上优于 X-Gaussian，同时使用更少的高斯点，在每帧渲染时间仅为 7.46 毫秒 [142]。此外，在术中 2D/3D 配准中，该方法相较传统解析 DRR 技术将关键点配准误差降低 62%。

尽管当前主要应用于 CT 成像，该前沿高斯表示方法若能推广至 MRI、PET 等模态，或将革新整个医学图像重建领域。

表 5: 基于高斯表示的放射图像重建相关工作。

模态	论文	年份	描述
CT	DIF-Gaussian [143]	2024	基于 3D 高斯特征和测试时优化的稀疏视角 CBCT 重建框架，提升解剖结构成像质量。
	R ² -Gaussian [45]	2024	一种新颖的 3D 高斯投影框架，纠正积分偏差，实现快速、精确的稀疏视角层析重建。
	GaSpCT [144]	2024	在不依赖结构光的情况下合成 CT 视角图像，减少扫描时间，提升前景与背景分离效果。
	DDGS-CT [142]	2024	一种方向解耦的 3D 高斯投影框架，模拟各向异性 X 射线效应，用于高效可微的 DRR 生成。
	X-Gaussian [141]	2024	基于 3D 高斯投影的高效框架，实现新视角 X 射线图像合成与稀疏 CT 图像快速重建。
	3DGR-CT [145]	2025	一种自监督 3D 高斯方法，结合 FBP 先验和自适应更新，实现稀疏视角 CT 的高效重建。
CT/MRI	GBIR [146]	2025	一种基于高斯的迭代重建框架，使用可学习的高斯点从欠采样数据中实现 CT 和 MRI 的个性化重建。

5 隐式重建方法

与直接编码特征或信号值的离散显式表示不同，隐式表示被定义为将输入坐标映射到输入空间中相应值的连续生成函数 [39]。现有的放射影像隐式表示方法可分为两大类：**隐式先验嵌入（Implicit Prior Embedding, IPE）**和**神经辐射场（Neural Radiance Fields, NRF）**。

隐式先验嵌入将先验信息融入表示空间或模型参数空间，使模型在训练过程中能够自动学习符合给定先验的特征。该方法已应用于 CT、PET 及多模态（multi-modality）影像等多种成像方式。相关文献综述见表 6。

神经辐射场（NRF）自提出以来，因其生成高分辨率、真实感图像及从任意角度渲染逼真 3D 视图的能力，在放射影像重建中引起广泛关注 [40]，目前已应用于超声（US）、CT、MRI 及多模态影像。相关文献综述见表 7。

下面将分别从这两种方法中挑选代表性论文进行探讨。

5.1 隐式先验嵌入

不同于传统显式先验嵌入，隐式先验嵌入是一种隐式神经表示学习方法，通过将先验影像信息嵌入神经网络架构中，实现放射影像重建 [147]。

该方法最初应用于 PET 成像，用于从低剂量图像中重建正常剂量图像。例如，Gong 等人将深度图像先验框架与非局部操作相结合，采用核矩阵层进行特征去噪，并将线性动力学模型作为卷积层嵌入 [148]。实验证明，该方法在图像质量和降噪效果上优于传统方法与核方法。

随后, NeRP [147] 将该方法扩展至多模态成像, 首次提出了一个统一的医学图像重建框架。该方法能捕捉用于肿瘤进展评估的重要细微图像变化, 从而提升重建质量。与以往方法不同, NeRP 使用隐式神经网络直接学习目标图像的连续表示, 避免了显式存储像素值。此外, 该方法集成了先验嵌入机制, 能有效提取结构信息, 并结合物理测量优化重建过程。通过使用多层感知机 (MLP) 将空间坐标映射为强度值, NeRP 在仅使用 20 次投影的条件下实现了 39.06 dB 的 PSNR 和 0.986 的 SSIM, 性能优于 FBP 和 GRFF 等方法。

多个研究 [149, 150] 表明, 隐式先验嵌入在将低剂量图像转换为正常剂量图像方面可实现高质量的放射影像重建。然而, 该方法存在一定局限性。首先, 它要求每位受试者至少进行一次正常剂量扫描, 极大限制了其应用范围 [147]。此外, 在实际应用中, 由于解剖结构差异、患者体位移动或设备不同, 先验图像并不总是可得, 从而难以实现与目标图像的完美对齐 [151]。

表 6: 基于隐式先验的放射图像重建相关工作。

模态	论文	年份	描述
CT	PINER [152]	2023	一种新颖的无源黑盒测试时自适应方法, 通过先验引导的隐式神经表示学习实现未知噪声下的稀疏视角 CT 重建。
PET	GONG et al. [148]	2022	一个用于动态 PET 参数图像重建的无监督深度学习框架, 采用将动力学模型嵌入卷积层的 3D U-Net 结构。
	Makkar et al. [153]	2024	一种基于深度学习的方法, 结合基于坐标的 MLP 隐式神经表示学习, 用于提升部分环 PET 扫描器中的图像质量。
CT/MRI	NeRP [147]	2022	一种将纵向信息和解剖结构先验融合到深度学习模型中的隐式神经表示方法, 用于从稀疏测量中重建医学图像。

5.2 神经辐射场

神经辐射场 (NeRF) 作为一种强大的 3D 重建与渲染技术, 逐渐受到关注。与依赖离散体积表示的传统方法不同, NeRF 在生成细节丰富医学图像方面表现优越 [40, 154], 尤其在 CT 重建任务中取得高质量结果。

MedNeRF [41] 是首个将 NeRF 应用于放射影像的研究。该方法基于自监督学习, 扩展了 GRAF 框架, 结合了针对医学领域的 GAN 架构。该方法引入数据增强技术, 在稀疏数据下实现高保真重建。在数字重建射线图 (DRR) 数据集上, MedNeRF 实现了 30.17 dB 的 PSNR 和 0.670 的 SSIM。然而, 由于其高度依赖单视角 X 射线进行 CT 重建, 生成图像中存在明显伪影, 限制了其临床应用。

VolumeNeRF [154] 采用 3D 编码器-解码器架构, 从 2D X 射线重建 CT 体积, 利用解剖先验 (来自概率图和平均 CT 图像) 提升结构一致性, 并引入投影注意力模块增强空间对齐。该方法结合基于 Lambert-Beer 定律的体积渲染, 进一步提升图像质量和边缘保留能力。

在超声领域, Ultra-NeRF [83] 是最具代表性的先驱方法之一。它为超声影像提出了一个基于隐式神经表示 (INR) 的新模型, 可通过多个二维扫描合成依赖视角的 B 模图像。该方法引入物理渲染公式, 并通过光线追踪模拟超声中组织特有的衰减、反射与散射等各向异性特性。与未集成渲染机制的 INR 模型相比, Ultra-NeRF 能更好地还原声影和遮挡现象, 在体积合成质量上亦具优势。

随后, Chen 等人提出了 CuNeRF [155], 这是一个零样本 (zero-shot) NeRF 框架, 适用于 CT 与 MRI 等多种影像模态。CuNeRF 无需高分辨率配对数据即可从低分辨率图像重建高分辨率体积, 采用立方网格采样、各向同性体积渲染及层次自适应采样策略。该方法不仅实现了自由视角合成, 还在多个设置中优于现有方法。

NeRF 在近几年受到广泛关注, 但其计算复杂度仍是阻碍其临床推广的关键瓶颈 [39]。该类方法需为每个信号单独学习神经表示, 导致显存和计算资源消耗巨大。尤其在处理 3D 体数据时, 训

练耗时严重。此外，由于采样稀疏，隐式重建结果易出现图像模糊与结构畸变，在医学成像中可能造成诊断误差。

表 7: 基于 NeRF 的放射图像重建相关工作。

模态	论文	年份	描述
US	ImplicitVol [156]	2021	一种用于从 2D 自由手超声图像中无传感器重建 3D 体积的深度隐式建模方法，基于空间到强度的隐式映射。
	Ultra-NeRF [83]	2024	基于光线追踪的方法，从多次超声扫描中学习视角相关的场景外观和几何，用于合成精确的 B 超图像。
	UIRe-NeRF [157]	2024	结合隐式神经网络和显式体积渲染的超声神经渲染模型，具有反射方向参数化和调和编码机制。
	NeRF-US [158]	2024	将 NeRF 应用于超声成像的方法，结合超声成像特性和扩散模型先验，同时使用超声特有的渲染方式。
CT	MedNeRF [41]	2022	一种基于 NeRF 的深度学习架构，从少量单视角 X 光图像中生成连续的 CT 表示。
	NAF [159]	2022	无需外部训练数据的自监督稀疏视角 CBCT 重建方法。
	DIF-Net [160]	2023	一种监督式 CBCT 重建框架，能从不超过 10 个视角获得高质量、高分辨率的 CBCT 图像。
	ACnerf [161]	2024	提升 NeRF 在单视角 X 射线 CT 重建中的对齐、姿态校正和渲染精度。
	UMedNeRF [162]	2024	基于辐射场网络，从 2D X 射线中重建连续 CT 投影，同时提取内部结构并优化多任务损失。
	VolumeNeRF [154]	2024	利用 NeRF 结合解剖结构先验和投影注意模块，从单视角 X 射线中重建 CT 体积。
	SAX-NeRF [163]	2024	通过引入 Lineformer 结构建模和局部-全局掩码光线采样，提升稀疏视角 X 射线 3D 重建效果。
MRI	Liu et al. [150]	2024	基于几何感知的编码器-解码器框架，通过先验知识和多视角 2D 特征的 3D 反投影，实现稀疏视角 CBCT 重建。
	extended-MedNeRF [164]	2023	一种基于 NeRF 的方式，从 2D MRI 切片重建 3D 投影图像。
	Feng et al. [165]	2025	一种基于隐式神经表示的无监督深度学习方法，仅使用时空坐标输入从高度欠采样的 k-space 数据中重建动态 MRI。
CT/MRI	Rao et al. [166]	2022	一种高效加速器，具备协同设计硬件架构，用于基于隐式神经表示的医学图像重建，优化数据复用和计算负载。
	NeSVoR [167]	2023	一种分辨率无关的切片到体积重建框架，将底层体积表示为一个连续的空间函数。
	CuNeRF [155]	2023	零样本医学图像超分辨率框架，无需高分辨率训练数据即可生成任意尺度和视角下的高质量图像。

6 讨论与挑战

6.1 重建表示方法的比较

基于前文的讨论，我们将基于人工智能的放射成像三维重建方法分为两大类：显式表示 (explicit) 和隐式表示 (implicit)。显式表示包括传统的切片 (slice-based) 和体素 (volume-based) 方法，以及新兴的高斯表示 (Gaussian representation)；隐式表示则涵盖了隐式神经辐射场 (Neural Radiance Fields, NRF) 和隐式先验嵌入 (Implicit Prior Embedding, IPE) 等方法。每种表示范式都有其独特的优缺点。

本节基于五个关键标准对上述方法进行比较：**有效性 (Effectv.)**、**效率 (Effcy.)**、**适应性 (Adapt.)**、**简洁性 (Simpl.)** 和 **可解释性 (Intrpt.)**。每项标准评分范围为 1 到 5，1 表示表现较差，5 表示在该方面表现较好。为对比，我们也引入了传统的基于概率的迭代重建方法 (Iterative) 作为参照。详细结果如表 8 所示。

如表 8 所示，由于缺乏空间信息，切片法在有效性方面受到限制。而隐式先验嵌入 (IPE) 通过整合先验知识，能获得更佳的重建性能。相比隐式表示，显式表示通常具有更高的效率。值得注意的是，高斯表示 (Gaussian) 由于其独特建模方式，可实现实时重建，在临床实时成像中具有应用潜力。

尽管高斯表示、IPE 和 NRF 等新型方法在有效性方面表现出色，但其适应性仍不如传统的切片和体积方法。研究人员往往需为不同任务或器官结构开发专用算法，从而降低了方法的通用性与

表 8: 不同重建表示方法的对比

方法	Effectv.	Effcy.	Adapt.	Simpl.	Intrpt.
迭代法 (Iterative)	1	3	5	5	5
切片法 (Slice-based)	1	4	5	5	3
体积法 (Volume-based)	2	3	4	4	2
高斯表示 (Gaussian)	4	5	2	2	2
隐式先验嵌入 (IPE)	5	3	1	2	3
神经辐射场 (NRF)	3	1	3	2	2

简洁性，进而限制其临床转化潜力。特别是 IPE 强依赖于先验图像，这使得其在临床中较难推广。

此外，相较于传统的概率迭代方法，现有所有 AI 重建方法在可解释性方面均面临挑战。

6.2 成像质量评估

随着人工智能推动放射成像三维重建的发展，重建方法从切片法 (4.1) 发展至体积法 (4.2)、高斯表示 (4.3) 及隐式方法 (5)，不断提升了 PSNR 和 SSIM 等指标 [168]。然而，医学成像质量评估不能仅依赖这些指标，还需考虑其临床意义 [169]，如伪影 (artifact) [170]、配准精度 [171] 及图像保真度 [172]。因此，临床医生的主观评价仍不可或缺。

在自然图像质量评估领域，研究表明将图像质量评估 (IQA) [173] 与图像质量度量 (IQM) [174] 结合，可更有效地评估图像质量。这种方法广泛应用于去模糊 [175] 和低光照图像增强 [176, 177] 等图像恢复任务。

在医学图像领域也有类似尝试 [178, 179, 180]。我们认为，广泛的临床评估比单纯追求指标更具实际价值。

同时，引入多样化且更具代表性的评价指标也有助于提升重建质量 [181]。无论是自然图像还是医学图像，选择合适的评估指标都有助于引导模型学习更深层次、更有意义的信息 [182, 183]。

6.3 效率与有效性

早期卷积神经网络能够实现快速但基本的图像重建 (4.1)，而更先进的扩散模型 (diffusion model) (4.2) 和 NeRF (5.2) 则在质量与速度之间存在权衡问题。高斯表示 (3DGS) (4.3) 利用并行计算提升了速度和保真度，在一定程度上解决了此问题。然而，如何在保证质量的同时加速重建，仍是医学影像 AI 的关键研究方向 [184, 185]。

迁移学习 (transfer learning) 可通过在大规模数据集上预训练并在特定任务上微调模型，降低训练时间与计算成本 [186]。该方法已广泛应用于医学图像分类 [187]、分割 [188] 等任务 [189]。尤其是 Segment Anything Model (SAM) [190] 在医学图像微调中展现了良好性能 [191]。但医学图像重建任务对图像特性要求更高，无法直接迁移，需要融入成像特有知识 [192, 193]。

边缘计算 (edge computing) 也是一项有前景的技术，可将重建任务分布至边缘设备或云平台，实现实时分布式处理 [194]。该技术在大型语言模型中已有广泛应用 [195]，在医学图像重建中也已开始探索其临床可行性 [196, 197, 198]。

同时，AI 技术推动下的低剂量和稀疏视角重建显著降低了成像成本，但高性能模型的计算资源消耗成为新的瓶颈。轻量化模型和知识蒸馏 (knowledge distillation) 成为解决方案之一 [199]。在分割任务中，Zhou 等人提出了一种基于图像重建指导的蒸馏方法 [200]。在图像重建中，Wu 等人引入了自监督训练、蒸馏与样本重加权结合的 MRI 重建方法 [201]，在多个数据集上提升了性能并加

速了推理。

6.4 隐私保护

由于医学成像数据具有高度敏感性，构建安全的 AI 重建方法至关重要 [202]。对此，研究者提出了多种解决方案：

首先，诸如高斯混合模型（GMM）[203]、无偏风险估计（URE）[204] 和基于 3DGS 的无监督模型 [205, 141] 等方法均无需训练数据集或外部信息，在保障隐私的同时完成图像重建 [206]。

联邦学习（federated learning）可在不传输患者数据的情况下完成模型训练 [207]，已成功应用于 MRI 重建，并在多机构分布上取得了与集中式训练相近的效果 [208, 209]。

此外，领域自适应（domain adaptation）[210, 211] 与领域泛化（domain generalization）[212] 技术有助于缓解公共数据与临床数据之间的领域偏移。近年来，Test-Time Training 成为热点研究方向 [213, 214]。

差分隐私（differential privacy）[215] 和同态加密（homomorphic encryption）[216, 217] 等技术也被应用于医学图像重建任务中，保障数据安全。

区块链（blockchain）在医疗数据共享中也逐渐受到关注 [218]，其去中心化与不可篡改的特性可提升数据交换的安全性及透明度 [219]。

6.5 模型可解释性

复杂的 AI 重建模型不透明性限制了其临床信任度 [220]。近年来，研究者通过将重建过程拆解为可追踪步骤以提升可解释性 [221]。目前主要分为两类：事前可解释（ante-hoc）[222, 223] 和事后可解释（post-hoc）[224, 225]。

在放射图像重建领域，Zhang 等人提出 DUN-SA，通过将优化算法中的迭代阶段展开为具有物理意义的网络模块，实现了多模态 MRI 重建的可解释性 [226]。

我们认为，提高 AI 重建模型的可解释性将显著推动其临床应用落地。

7 结论

随着人工智能中计算机视觉技术的发展，其在医学图像分析中的应用日益广泛。本文综述主要聚焦人工智能在放射成像三维重建中的应用，涵盖了包括 CT、MRI、PET、SPECT 和 US 在内的多种成像模态。过去五年中，基于人工智能的放射成像三维重建算法研究显著增长，相关文献数量持续上升。本综述根据图像重建方式将现有研究划分为显式重建方法和隐式重建方法，并系统地讨论了这两种表示范式的发展历程、优势与局限性。鉴于医学成像的特殊性，人工智能算法需在图像质量、计算效率与成像成本之间寻求平衡。随着算法研究不断深入，预计未来将有更多研究者提出更高效的重建方法，在有限的计算时间和成本下提升医学图像质量。展望未来，人工智能有望通过端到端系统实现低成本、高质量的医学图像重建，推动快速且经济的成像解决方案落地应用。

参考文献

- [1] D Sanghvi and MG Harisinghani. “Modalities in modern radiology: A synopsis”. In: *Journal of postgraduate medicine* 56.2 (2010), pp. 85–87.
- [2] Dinggang Shen, Guorong Wu, and Heung-Il Suk. “Deep learning in medical image analysis”. In: *Annual review of biomedical engineering* 19.1 (2017), pp. 221–248.
- [3] Hanene Ben Yedder, Ben Cardoen, and Ghassan Hamarneh. “Deep learning for biomedical image reconstruction: A survey”. In: *Artificial intelligence review* 54.1 (2021), pp. 215–251.
- [4] Satya P Singh et al. “3D deep learning on medical images: a review”. In: *Sensors* 20.18 (2020), p. 5097.
- [5] Jonathan M Blackledge. *Digital image processing: mathematical and computational methods*. Elsevier, 2005.
- [6] Ritu Gothwal, Shailendra Tiwari, and Shivendra Shivani. “Computational medical image reconstruction techniques: a comprehensive review”. In: *Archives of Computational Methods in Engineering* 29.7 (2022), pp. 5635–5662.
- [7] Hongli Shi et al. “A novel iterative CT reconstruction approach based on FBP algorithm”. In: *PLoS one* 10.9 (2015), e0138498.
- [8] James W Cooley, Peter AW Lewis, and Peter D Welch. “The fast Fourier transform and its applications”. In: *IEEE Transactions on Education* 12.1 (1969), pp. 27–34.
- [9] Thilaka Sumanaweera and Donald Liu. “Medical image reconstruction with the FFT”. In: *GPU gems* 2 (2005), pp. 765–784.
- [10] Kyong Hwan Jin et al. “Deep convolutional neural network for inverse problems in imaging”. In: *IEEE transactions on image processing* 26.9 (2017), pp. 4509–4522.
- [11] Jeffrey A Fessler. “Medical image reconstruction: a brief overview of past milestones and future directions”. In: *arXiv preprint arXiv:1707.05927* (2017).
- [12] Richard Gordon, Robert Bender, and Gabor T Herman. “Algebraic reconstruction techniques (ART) for three-dimensional electron microscopy and X-ray photography”. In: *Journal of theoretical Biology* 29.3 (1970), pp. 471–481.
- [13] Saiprasad Ravishankar, Jong Chul Ye, and Jeffrey A Fessler. “Image reconstruction: From sparsity to data-adaptive methods and machine learning”. In: *Proceedings of the IEEE* 108.1 (2019), pp. 86–109.
- [14] H Malcolm Hudson and Richard S Larkin. “Accelerated image reconstruction using ordered subsets of projection data”. In: *IEEE transactions on medical imaging* 13.4 (1994), pp. 601–609.
- [15] Rutao Yao et al. “Performance characteristics of the 3-D OSEM algorithm in the reconstruction of small animal PET images”. In: *IEEE transactions on medical imaging* 19.8 (2000), pp. 798–804.

- [16] E Rapisarda et al. “Image-based point spread function implementation in a fully 3D OSEM reconstruction algorithm for PET”. In: *Physics in medicine & biology* 55.14 (2010), p. 4131.
- [17] Yehuda Vardi, Larry A Shepp, and Linda Kaufman. “A statistical model for positron emission tomography”. In: *Journal of the American statistical Association* 80.389 (1985), pp. 8–20.
- [18] Ge Wang, Jong Chul Ye, and Bruno De Man. “Deep learning for tomographic image reconstruction”. In: *Nature machine intelligence* 2.12 (2020), pp. 737–748.
- [19] Abdulhamit Subasi. “Artificial intelligence for 3D medical image analysis”. In: *Applications of Artificial Intelligence Healthcare and Biomedicine*. Elsevier, 2024, pp. 357–375.
- [20] Ahmed Hosny et al. “Artificial intelligence in radiology”. In: *Nature Reviews Cancer* 18.8 (2018), pp. 500–510.
- [21] Shijun Wang and Ronald M Summers. “Machine learning and radiology”. In: *Medical image analysis* 16.5 (2012), pp. 933–951.
- [22] Yann LeCun et al. “Backpropagation applied to handwritten zip code recognition”. In: *Neural computation* 1.4 (1989), pp. 541–551.
- [23] Chao Chen, Nor Ashidi Mat Isa, and Xin Liu. “A review of convolutional neural network based methods for medical image classification”. In: *Computers in Biology and Medicine* 185 (2025), p. 109507.
- [24] Jakub Jurek et al. “CNN-based superresolution reconstruction of 3D MR images using thick-slice scans”. In: *Biocybernetics and Biomedical Engineering* 40.1 (2020), pp. 111–125.
- [25] Kuang Gong et al. “Iterative PET image reconstruction using convolutional neural network representation”. In: *IEEE transactions on medical imaging* 38.3 (2018), pp. 675–685.
- [26] Laith Alzubaidi et al. “Review of deep learning: concepts, CNN architectures, challenges, applications, future directions”. In: *Journal of big Data* 8 (2021), pp. 1–74.
- [27] A Waswani et al. “Attention is all you need”. In: *NIPS*. 2017.
- [28] Alexey Dosovitskiy et al. “An image is worth 16x16 words: Transformers for image recognition at scale”. In: *arXiv preprint arXiv:2010.11929* (2020).
- [29] Reza Azad et al. “Advances in medical image analysis with vision transformers: a comprehensive review”. In: *Medical Image Analysis* 91 (2024), p. 103000.
- [30] Anas M Ali et al. “Vision transformers in image restoration: A survey”. In: *Sensors* 23.5 (2023), p. 2385.
- [31] Diederik P Kingma, Max Welling, et al. *Auto-encoding variational bayes*. 2013.
- [32] Ian Goodfellow et al. “Generative adversarial nets”. In: *Advances in neural information processing systems* 27 (2014).
- [33] Yanmei Luo et al. “3D transformer-GAN for high-quality PET reconstruction”. In: *Medical Image Computing and Computer Assisted Intervention–MICCAI 2021: 24th International Conference, Strasbourg, France, September 27–October 1, 2021, Proceedings, Part VI* 24. Springer. 2021, pp. 276–285.

- [34] Arjun Sriram et al. “Challenges and Opportunities in Malignant Image Reconstruction Using GAN: A Review”. In: *2024 IEEE Integrated STEM Education Conference (ISEC)*. IEEE. 2024, pp. 01–06.
- [35] Florinel-Alin Croitoru et al. “Diffusion models in vision: A survey”. In: *IEEE Transactions on Pattern Analysis and Machine Intelligence* 45.9 (2023), pp. 10850–10869.
- [36] George Webber and Andrew J Reader. “Diffusion models for medical image reconstruction”. In: *BJR/ Artificial Intelligence* 1.1 (2024), ubae013.
- [37] Alper Güngör et al. “Adaptive diffusion priors for accelerated MRI reconstruction”. In: *Medical image analysis* 88 (2023), p. 102872.
- [38] Minshuo Chen et al. “Opportunities and challenges of diffusion models for generative AI”. In: *National Science Review* 11.12 (2024), nwae348.
- [39] Amirali Molaei et al. “Implicit neural representation in medical imaging: A comparative survey”. In: *Proceedings of the IEEE/CVF International Conference on Computer Vision*. 2023, pp. 2381–2391.
- [40] Ben Mildenhall et al. “Nerf: Representing scenes as neural radiance fields for view synthesis”. In: *Communications of the ACM* 65.1 (2021), pp. 99–106.
- [41] Abril Corona-Figueroa et al. “Mednerf: Medical neural radiance fields for reconstructing 3d-aware ct-projections from a single x-ray”. In: *2022 44th annual international conference of the IEEE engineering in medicine & Biology society (EMBC)*. IEEE. 2022, pp. 3843–3848.
- [42] Xin Wang et al. “Neural Radiance Fields in Medical Imaging: Challenges and Next Steps”. In: *arXiv preprint arXiv:2402.17797* (2024).
- [43] Bernhard Kerbl et al. “3D Gaussian splatting for real-time radiance field rendering.” In: *ACM Trans. Graph.* 42.4 (2023), pp. 139–1.
- [44] Ben Fei et al. “3d gaussian splatting as new era: A survey”. In: *IEEE Transactions on Visualization and Computer Graphics* (2024).
- [45] Ruyi Zha et al. “ R^2 -Gaussian: Rectifying Radiative Gaussian Splatting for Tomographic Reconstruction”. In: *arXiv preprint arXiv:2405.20693* (2024).
- [46] Emmanuel Ahishakiye et al. “A survey on deep learning in medical image reconstruction”. In: *Intelligent Medicine* 1.03 (2021), pp. 118–127.
- [47] Mussarat Yasmin et al. “Brain image reconstruction: A short survey”. In: *World Applied Sciences Journal* 19.1 (2012), pp. 52–62.
- [48] Wenjun Xia et al. “Physics-/model-based and data-driven methods for low-dose computed tomography: A survey”. In: *IEEE signal processing magazine* 40.2 (2023), pp. 89–100.
- [49] Mriganka Sarmah, Arambam Neelima, and Heisnam Rohen Singh. “Survey of methods and principles in three-dimensional reconstruction from two-dimensional medical images”. In: *Visual computing for industry, biomedicine, and art* 6.1 (2023), p. 15.
- [50] Johann Li et al. “A systematic collection of medical image datasets for deep learning”. In: *ACM Computing Surveys* 56.5 (2023), pp. 1–51.

- [51] Jean Ogier du Terrail et al. “Flamby: Datasets and benchmarks for cross-silo federated learning in realistic healthcare settings”. In: *Advances in Neural Information Processing Systems* 35 (2022), pp. 5315–5334.
- [52] Jennifer Kulynych and Henry T Greely. “Clinical genomics, big data, and electronic medical records: reconciling patient rights with research when privacy and science collide”. In: *Journal of Law and the Biosciences* 4.1 (2017), pp. 94–132.
- [53] Maximilian T Löffler et al. “A vertebral segmentation dataset with fracture grading”. In: *Radiology: Artificial Intelligence* 2.4 (2020), e190138.
- [54] Anjany Sekuboyina et al. “VerSe: a vertebrae labelling and segmentation benchmark for multi-detector CT images”. In: *Medical image analysis* 73 (2021), p. 102166.
- [55] Hans Liebl et al. “A computed tomography vertebral segmentation dataset with anatomical variations and multi-vendor scanner data”. In: *Scientific data* 8.1 (2021), p. 284.
- [56] Samuel G Armato III et al. “The lung image database consortium (LIDC) and image database resource initiative (IDRI): a completed reference database of lung nodules on CT scans”. In: *Medical physics* 38.2 (2011), pp. 915–931.
- [57] Jinyu Zhao et al. “COVID-CT-Dataset: A CT Scan Dataset about COVID-19”. In: *CoRR* abs/2003.13865 (2020). arXiv: 2003.13865. URL: <https://arxiv.org/abs/2003.13865>.
- [58] Richard Castillo et al. “A framework for evaluation of deformable image registration spatial accuracy using large landmark point sets”. In: *Physics in Medicine & Biology* 54.7 (2009), p. 1849.
- [59] Nicholas Heller et al. “The kits19 challenge data: 300 kidney tumor cases with clinical context, ct semantic segmentations, and surgical outcomes”. In: *arXiv preprint arXiv:1904.00445* (2019).
- [60] Taylor R Moen et al. “Low-dose CT image and projection dataset”. In: *Medical physics* 48.2 (2021), pp. 902–911.
- [61] Yang Deng et al. “CTSpine1K: a large-scale dataset for spinal vertebrae segmentation in computed tomography”. In: *arXiv preprint arXiv:2105.14711* (2021).
- [62] E. B. Tsai et al. *Medical Imaging Data Resource Center (MIDRC) - RSNA International COVID Open Research Database (RICORD) Release 1b - Chest CT Covid- (Version 1) [Data set]*. 2021. URL: <https://doi.org/10.7937/31V8-4A40>.
- [63] Spyridon Bakas et al. *RSNA-MICCAI Brain Tumor Segmentation (BraTS) Challenge 2021*. Mar. 2021. DOI: 10.5281/zenodo.4575162.
- [64] Mariam Aboian et al. *MICCAI 2025 Lighthouse Challenge: Brain Tumor Segmentation Cluster of Challenges (BraTS)*. Oct. 2024. DOI: 10.5281/zenodo.13981216.
- [65] Spyridon Bakas et al. *The International Brain Tumor Segmentation (BraTS) Cluster of Challenges*. Apr. 2023. DOI: 10.5281/zenodo.7837974.
- [66] Spyridon Bakas et al. *BraTS 2024 Cluster of Challenges (BraTS + Beyond- BraTS)*. Apr. 2024. DOI: 10.5281/zenodo.10978907.

- [67] Spyridon Bakas et al. *The Brain Tumor Segmentation Challenge (2022 Continuous Updates & Generalizability Assessment)*. Mar. 2022. DOI: 10.5281/zenodo.6362180.
- [68] Spyridon Bakas et al. *MICCAI Brain Tumor Segmentation (BraTS) 2020 Benchmark: "Prediction of Survival and Pseudoprogression"*. Mar. 2020. DOI: 10.5281/zenodo.3718904.
- [69] Mariana-Iuliana Georgescu et al. "Multimodal multi-head convolutional attention with various kernel sizes for medical image super-resolution". In: *Proceedings of the IEEE/CVF winter conference on applications of computer vision*. 2023, pp. 2195–2205.
- [70] Clifford R Jack Jr et al. "The Alzheimer's disease neuroimaging initiative (ADNI): MRI methods". In: *Journal of Magnetic Resonance Imaging: An Official Journal of the International Society for Magnetic Resonance in Medicine* 27.4 (2008), pp. 685–691.
- [71] Daniel S Marcus et al. "Open Access Series of Imaging Studies (OASIS): cross-sectional MRI data in young, middle aged, nondemented, and demented older adults". In: *Journal of cognitive neuroscience* 19.9 (2007), pp. 1498–1507.
- [72] Florian Knoll et al. "fastMRI: A publicly available raw k-space and DICOM dataset of knee images for accelerated MR image reconstruction using machine learning". In: *Radiology: Artificial Intelligence* 2.1 (2020), e190007.
- [73] Jure Zbontar et al. "fastMRI: An open dataset and benchmarks for accelerated MRI". In: *arXiv preprint arXiv:1811.08839* (2018).
- [74] David C Van Essen et al. "The WU-Minn human connectome project: an overview". In: *Neuroimage* 80 (2013), pp. 62–79.
- [75] Bennett A Landman et al. "Multi-parametric neuroimaging reproducibility: a 3-T resource study". In: *Neuroimage* 54.4 (2011), pp. 2854–2866.
- [76] Emer J Hughes et al. "A dedicated neonatal brain imaging system". In: *Magnetic resonance in medicine* 78.2 (2017), pp. 794–804.
- [77] Amber L Simpson et al. "A large annotated medical image dataset for the development and evaluation of segmentation algorithms". In: *arXiv preprint arXiv:1902.09063* (2019).
- [78] Xiaoming Zhao et al. "BreastDM: A DCE-MRI dataset for breast tumor image segmentation and classification". In: *Computers in Biology and Medicine* 164 (2023), p. 107255.
- [79] Chong Chen et al. "OCMR (v1. 0)–open-access multi-coil k-space dataset for cardiovascular magnetic resonance imaging". In: *arXiv preprint arXiv:2008.03410* (2020).
- [80] Arjun D Desai et al. "Skm-tea: A dataset for accelerated mri reconstruction with dense image labels for quantitative clinical evaluation". In: *arXiv preprint arXiv:2203.06823* (2022).
- [81] Zi Wang et al. "CMRxRecon2024: A Multimodality, Multiview k-Space Dataset Boosting Universal Machine Learning for Accelerated Cardiac MRI". In: *Radiology: Artificial Intelligence* 7.2 (2025), e240443.
- [82] Kuangyu Shi et al. *Ultra-low Dose PET Imaging Challenge 2022*. Mar. 2022. DOI: 10.5281/zenodo.6361846. URL: <https://doi.org/10.5281/zenodo.6361846>.

- [83] Magdalena Wysocki et al. “Ultra-nerf: Neural radiance fields for ultrasound imaging”. In: *Medical Imaging with Deep Learning*. PMLR. 2024, pp. 382–401.
- [84] Debbie Zhao et al. “MITEA: A dataset for machine learning segmentation of the left ventricle in 3D echocardiography using subject-specific labels from cardiac magnetic resonance imaging”. In: *Frontiers in Cardiovascular Medicine* 9 (2023), p. 1016703.
- [85] Aris T Papageorghiou et al. “International standards for fetal growth based on serial ultrasound measurements: the Fetal Growth Longitudinal Study of the INTERGROWTH-21st Project”. In: *The Lancet* 384.9946 (2014), pp. 869–879.
- [86] Xiahai Zhuang et al. “Evaluation of algorithms for multi-modality whole heart segmentation: an open-access grand challenge”. In: *Medical image analysis* 58 (2019), p. 101537.
- [87] Pamela J LaMontagne et al. “IC-P-164: OASIS-3: LONGITUDINAL NEUROIMAGING, CLINICAL, AND COGNITIVE DATASET FOR NORMAL AGING AND ALZHEIMER’S DISEASE”. In: *Alzheimer’s & Dementia* 14.7S_Part_2 (2018), P138–P138.
- [88] ZMC Baum et al. *MR to Ultrasound Registration for Prostate Challenge-Dataset*. 2023.
- [89] Bradley J Erickson and Felipe Kitamura. *Magician’s corner: 9. Performance metrics for machine learning models*. 2021.
- [90] Olaf Ronneberger, Philipp Fischer, and Thomas Brox. “U-net: Convolutional networks for biomedical image segmentation”. In: *Medical image computing and computer-assisted intervention–MICCAI 2015: 18th international conference, Munich, Germany, October 5-9, 2015, proceedings, part III* 18. Springer. 2015, pp. 234–241.
- [91] Jinglong Du et al. “Super-resolution reconstruction of single anisotropic 3D MR images using residual convolutional neural network”. In: *Neurocomputing* 392 (2020), pp. 209–220.
- [92] Changrong Shi, Yongshun Xiao, and Zhiqiang Chen. “Dual-domain sparse-view CT reconstruction with Transformers”. In: *Physica Medica* 101 (2022), pp. 1–7.
- [93] Albert Gu and Tri Dao. “Mamba: Linear-time sequence modeling with selective state spaces”. In: *arXiv preprint arXiv:2312.00752* (2023).
- [94] Jiahao Huang et al. “Enhancing global sensitivity and uncertainty quantification in medical image reconstruction with Monte Carlo arbitrary-masked mamba”. In: *Medical Image Analysis* 99 (2025), p. 103334.
- [95] Bo Peng et al. “Rwkv: Reinventing rnns for the transformer era”. In: *arXiv preprint arXiv:2305.13048* (2023).
- [96] Zhiwen Yang et al. “Restore-rwkv: Efficient and effective medical image restoration with rwkv”. In: *arXiv preprint arXiv:2407.11087* (2024).
- [97] Ce Wang et al. “DuDoTrans: dual-domain transformer for sparse-view CT reconstruction”. In: *International Workshop on Machine Learning for Medical Image Reconstruction*. Springer. 2022, pp. 84–94.
- [98] Qi Gao et al. “CoreDiff: Contextual error-modulated generalized diffusion model for low-dose CT denoising and generalization”. In: *IEEE Transactions on Medical Imaging* (2023).

- [99] Daming Shen et al. “Rapid reconstruction of highly undersampled, non-Cartesian real-time cine k-space data using a perceptual complex neural network (PCNN)”. In: *NMR in Biomedicine* 34.1 (2021), e4405.
- [100] Yilmaz Korkmaz et al. “Unsupervised MRI Reconstruction via Zero-Shot Learned Adversarial Transformers”. In: *IEEE Transactions on Medical Imaging* 41.7 (2022), pp. 1747–1763. DOI: 10.1109/TMI.2022.3147426.
- [101] Ran Wei et al. “Real-time 3D MRI reconstruction from cine-MRI using unsupervised network in MRI-guided radiotherapy for liver cancer”. In: *Medical Physics* 50.6 (2023), pp. 3584–3596.
- [102] Jiaqi Cui et al. “MCAD: Multi-modal Conditioned Adversarial Diffusion Model for High-Quality PET Image Reconstruction”. In: *International Conference on Medical Image Computing and Computer-Assisted Intervention*. Springer. 2024, pp. 467–477.
- [103] Yan Wang et al. “3D multi-modality Transformer-GAN for high-quality PET reconstruction”. In: *Medical Image Analysis* 91 (2024), p. 102983.
- [104] Imraj RD Singh et al. “Score-Based Generative Models for PET Image Reconstruction”. In: *Machine Learning for Biomedical Imaging 2* (Special Issue for Generative Models 2024), pp. 547–585. ISSN: 2766-905X. DOI: <https://doi.org/10.59275/j.melba.2024-5d51>. URL: <https://melba-journal.org/2024:001>.
- [105] Farnaz Yousefzadeh et al. “SPECT-MPI iterative denoising during the reconstruction process using a two-phase learned convolutional neural network”. In: *EJNMMI physics* 11.1 (2024), pp. 1–22.
- [106] Karl Heinz Hohne et al. “A volume-based anatomical atlas”. In: *IEEE Computer Graphics and Applications* 12.04 (1992), pp. 73–77.
- [107] Min Chen, Arie E Kaufman, and Roni Yagel. *Volume graphics*. Springer Science & Business Media, 2012.
- [108] Roy Shaul et al. “Subsampled brain MRI reconstruction by generative adversarial neural networks”. In: *Medical Image Analysis* 65 (2020), p. 101747.
- [109] Xingde Ying et al. “X2CT-GAN: reconstructing CT from biplanar X-rays with generative adversarial networks”. In: *Proceedings of the IEEE/CVF conference on computer vision and pattern recognition*. 2019, pp. 10619–10628.
- [110] Vandana Kushwaha, GC Nandi, et al. “Study of prevention of mode collapse in generative adversarial network (gan)”. In: *2020 IEEE 4th Conference on Information & Communication Technology (CICT)*. IEEE. 2020, pp. 1–6.
- [111] Jascha Sohl-Dickstein et al. “Deep unsupervised learning using nonequilibrium thermodynamics”. In: *International conference on machine learning*. pmlr. 2015, pp. 2256–2265.
- [112] Jonathan Ho, Ajay Jain, and Pieter Abbeel. “Denoising diffusion probabilistic models”. In: *Advances in neural information processing systems* 33 (2020), pp. 6840–6851.
- [113] Jiaming Song, Chenlin Meng, and Stefano Ermon. “Denoising diffusion implicit models”. In: *arXiv preprint arXiv:2010.02502* (2020).

- [114] Robin Rombach et al. “High-resolution image synthesis with latent diffusion models”. In: *Proceedings of the IEEE/CVF conference on computer vision and pattern recognition*. 2022, pp. 10684–10695.
- [115] Hyungjin Chung et al. “Solving 3d inverse problems using pre-trained 2d diffusion models”. In: *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*. 2023, pp. 22542–22551.
- [116] Kuang Gong et al. “PET image denoising based on denoising diffusion probabilistic model”. In: *European Journal of Nuclear Medicine and Molecular Imaging* 51.2 (2024), pp. 358–368.
- [117] Kyra E Stull et al. “Accuracy and reliability of measurements obtained from computed tomography 3D volume rendered images”. In: *Forensic science international* 238 (2014), pp. 133–140.
- [118] Guoyan Zheng. “Effective incorporating spatial information in a mutual information based 3D–2D registration of a CT volume to X-ray images”. In: *Computerized medical imaging and graphics* 34.7 (2010), pp. 553–562.
- [119] Fang Xu and Klaus Mueller. “Real-time 3D computed tomographic reconstruction using commodity graphics hardware”. In: *Physics in Medicine & Biology* 52.12 (2007), p. 3405.
- [120] Klaus Engel et al. “Real-time volume graphics”. In: *ACM Siggraph 2004 Course Notes*. 2004, 29–es.
- [121] Huidong Xie et al. “Deep Efficient End-to-End Reconstruction (DEER) Network for Few-View Breast CT Image Reconstruction”. In: *IEEE Access* 8 (2020), pp. 196633–196646. DOI: 10.1109/ACCESS.2020.3033795.
- [122] Dianlin Hu et al. “Hybrid-domain neural network processing for sparse-view CT reconstruction”. In: *IEEE Transactions on Radiation and Plasma Medical Sciences* 5.1 (2020), pp. 88–98.
- [123] Ramandeep Singh et al. “Image quality and lesion detection on deep learning reconstruction and iterative reconstruction of submillisievert chest and abdominal CT”. In: *American Journal of Roentgenology* 214.3 (2020), pp. 566–573.
- [124] Samuel L Brady et al. “Improving image quality and reducing radiation dose for pediatric CT by using deep learning reconstruction”. In: *Radiology* 298.1 (2021), pp. 180–188.
- [125] Dianlin Hu et al. “DIOR: Deep iterative optimization-based residual-learning for limited-angle CT reconstruction”. In: *IEEE Transactions on Medical Imaging* 41.7 (2022), pp. 1778–1790.
- [126] Chenglong Ma et al. “FreeSeed: Frequency-band-aware and self-guided network for sparse-view CT reconstruction”. In: *International Conference on Medical Image Computing and Computer-Assisted Intervention*. Springer. 2023, pp. 250–259.
- [127] Yiqun Lin et al. “C²RV: Cross-Regional and Cross-View Learning for Sparse-View CBCT Reconstruction”. In: *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*. June 2024, pp. 11205–11214.

- [128] Nicola Pezzotti et al. “An adaptive intelligence algorithm for undersampled knee MRI reconstruction”. In: *IEEE Access* 8 (2020), pp. 204825–204838.
- [129] Defu Qiu et al. “Super-resolution reconstruction of knee magnetic resonance imaging based on deep learning”. In: *Computer methods and programs in biomedicine* 187 (2020), p. 105059.
- [130] Thomas Küstner et al. “CINENet: deep learning-based 3D cardiac CINE MRI reconstruction with multi-coil complex-valued 4D spatio-temporal convolutions”. In: *Scientific reports* 10.1 (2020), p. 13710.
- [131] Changhee Han et al. “MADGAN: Unsupervised medical anomaly detection GAN using multiple adjacent brain MRI slice reconstruction”. In: *BMC bioinformatics* 22 (2021), pp. 1–20.
- [132] Neha Koonjoo et al. “Boosting the signal-to-noise of low-field MRI with deep learning image reconstruction”. In: *Scientific reports* 11.1 (2021), p. 8248.
- [133] Eric Z Chen et al. “Computationally Efficient 3D MRI Reconstruction with Adaptive MLP”. In: *International Conference on Medical Image Computing and Computer-Assisted Intervention*. Springer. 2023, pp. 195–205.
- [134] Li Kang et al. “3D-MRI super-resolution reconstruction using multi-modality based on multi-resolution CNN”. In: *Computer Methods and Programs in Biomedicine* 248 (2024), p. 108110.
- [135] William Whiteley, Wing K Luk, and Jens Gregor. “DirectPET: full-size neural network PET reconstruction from sinogram data”. In: *Journal of Medical Imaging* 7.3 (2020), pp. 032503–032503.
- [136] Abolfazl Mehranian et al. “Image enhancement of whole-body oncology [18F]-FDG PET scans using deep neural networks to reduce noise”. In: *European journal of nuclear medicine and molecular imaging* 49.2 (2022), pp. 539–549.
- [137] Daniel Deidda et al. “Triple modality image reconstruction of PET data using SPECT, PET, CT information increases lesion uptake in images of patients treated with radioembolization with 90 Y micro-spheres”. In: *EJNMMI physics* 10.1 (2023), p. 30.
- [138] Fumio Hashimoto et al. “Fully 3D implementation of the end-to-end deep image prior-based PET image reconstruction using block iterative algorithm”. In: *Physics in Medicine & Biology* 68.15 (2023), p. 155009.
- [139] Samaneh Mostafapour et al. “Deep learning-guided attenuation correction in the image domain for myocardial perfusion SPECT imaging”. In: *Journal of computational design and engineering* 9.2 (2022), pp. 434–447.
- [140] Guikun Chen and Wenguan Wang. “A survey on 3d gaussian splatting”. In: *arXiv preprint arXiv:2401.03890* (2024).
- [141] Yuanhao Cai et al. “Radiative gaussian splatting for efficient x-ray novel view synthesis”. In: *European Conference on Computer Vision*. Springer. 2025, pp. 283–299.

- [142] Zhongpai Gao et al. “DDGS-CT: Direction-Disentangled Gaussian Splatting for Realistic Volume Rendering”. In: *The Thirty-eighth Annual Conference on Neural Information Processing Systems*. 2024. URL: <https://openreview.net/forum?id=mY0ZnS2s9u>.
- [143] Yiqun Lin et al. “Learning 3D Gaussians for extremely sparse-view cone-beam CT reconstruction”. In: *International Conference on Medical Image Computing and Computer-Assisted Intervention*. Springer. 2024, pp. 425–435.
- [144] Emmanouil Nikolakakis et al. “GaSpCT: Gaussian Splatting for Novel CT Projection View Synthesis”. In: *arXiv preprint arXiv:2404.03126* (2024).
- [145] Yingtai Li et al. “3DGR-CT: Sparse-view CT reconstruction with a 3D Gaussian representation”. In: *Medical Image Analysis* (2025), p. 103585.
- [146] Shaokai Wu et al. *GBIR: A Novel Gaussian Iterative Method for Medical Image Reconstruction*. 2024. URL: <https://openreview.net/forum?id=AkCWbxnt11>.
- [147] Liyue Shen, John Pauly, and Lei Xing. “NeRP: implicit neural representation learning with prior embedding for sparsely sampled image reconstruction”. In: *IEEE Transactions on Neural Networks and Learning Systems* 35.1 (2022), pp. 770–782.
- [148] Kuang Gong et al. “Direct reconstruction of linear parametric images from dynamic PET using nonlocal deep image prior”. In: *IEEE transactions on medical imaging* 41.3 (2021), pp. 680–689.
- [149] Jiayang Shi et al. “Implicit neural representations for robust joint sparse-view CT reconstruction”. In: *arXiv preprint arXiv:2405.02509* (2024).
- [150] Zhentao Liu et al. “Geometry-Aware Attenuation Learning for Sparse-View CBCT Reconstruction”. In: *IEEE Transactions on Medical Imaging* (2024).
- [151] Ben Adlam et al. “Exploring the uncertainty properties of neural networks’ implicit priors in the infinite-width limit”. In: *arXiv preprint arXiv:2010.07355* (2020).
- [152] Bowen Song, Liyue Shen, and Lei Xing. “PINER: Prior-informed Implicit Neural Representation Learning for Test-time Adaptation in Sparse-view CT Reconstruction”. In: *2023 IEEE/CVF Winter Conference on Applications of Computer Vision (WACV)*. 2023, pp. 1928–1937. DOI: 10.1109/WACV56688.2023.00197.
- [153] Shubhangi Makkar et al. “Partial-ring PET Image Correction using Implicit Neural Representation Learning”. In: ().
- [154] Jiachen Liu and Xiangzhi Bai. “VolumeNeRF: CT Volume Reconstruction from a Single Projection View”. In: *proceedings of Medical Image Computing and Computer Assisted Intervention – MICCAI 2024*. Vol. LNCS 15007. Springer Nature Switzerland, Oct. 2024.
- [155] Zixuan Chen et al. “CuNeRF: Cube-based neural radiance field for zero-shot medical image arbitrary-scale super resolution”. In: *Proceedings of the IEEE/CVF International Conference on Computer Vision*. 2023, pp. 21185–21195.
- [156] Pak-Hei Yeung et al. “Implicitvol: Sensorless 3d ultrasound reconstruction with deep implicit representation”. In: *arXiv preprint arXiv:2109.12108* (2021).

- [157] Ziwen Guo, Zi Fang, and Zhuang Fu. “UIRe-NeRF: 3D Ultrasound Imaging through Neural Rendering with Ultrasound Reflection Direction Parameterization”. In: *arXiv preprint arXiv:2408.00860* (2024).
- [158] Rishit Dagli et al. “Nerf-us: Removing ultrasound imaging artifacts from neural radiance fields in the wild”. In: *arXiv preprint arXiv:2408.10258* (2024).
- [159] Ruyi Zha, Yanhao Zhang, and Hongdong Li. “NAF: neural attenuation fields for sparse-view CBCT reconstruction”. In: *International Conference on Medical Image Computing and Computer-Assisted Intervention*. Springer. 2022, pp. 442–452.
- [160] Yiqun Lin et al. “Learning deep intensity field for extremely sparse-view CBCT reconstruction”. In: *International Conference on Medical Image Computing and Computer-Assisted Intervention*. Springer. 2023, pp. 13–23.
- [161] Mengcheng Sun et al. “ACnerf: enhancement of neural radiance field by alignment and correction of pose to reconstruct new views from a single x-ray”. In: *Physics in Medicine & Biology* 69.4 (2024), p. 045016.
- [162] Jing Hu et al. “UMedNeRF: Uncertainty-aware single view volumetric rendering for medical neural radiance fields”. In: *2024 IEEE International Symposium on Biomedical Imaging (ISBI)*. IEEE. 2024, pp. 1–4.
- [163] Yuanhao Cai et al. “Structure-aware sparse-view x-ray 3d reconstruction”. In: *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*. 2024, pp. 11174–11183.
- [164] Khadija Iddrisu, Sylwia Malec, and Alessandro Crimi. “3D reconstructions of brain from MRI scans using neural radiance fields”. In: *International Conference on Artificial Intelligence and Soft Computing*. Springer. 2023, pp. 207–218.
- [165] Jie Feng et al. “Spatiotemporal implicit neural representation for unsupervised dynamic MRI reconstruction”. In: *IEEE Transactions on Medical Imaging* (2025).
- [166] Chaolin Rao et al. “An energy-efficient accelerator for medical image reconstruction from implicit neural representation”. In: *IEEE Transactions on Circuits and Systems I: Regular Papers* 70.4 (2022), pp. 1625–1638.
- [167] Junshen Xu et al. “NeSVoR: implicit neural representation for slice-to-volume reconstruction in MRI”. In: *IEEE transactions on medical imaging* 42.6 (2023), pp. 1707–1719.
- [168] Zhou Wang et al. “Image quality assessment: from error visibility to structural similarity”. In: *IEEE transactions on image processing* 13.4 (2004), pp. 600–612.
- [169] Li Sze Chow and Raveendran Paramesran. “Review of medical image quality assessment”. In: *Biomedical signal processing and control* 27 (2016), pp. 145–154.
- [170] W Wuest et al. “Improved image quality in head and neck CT using a 3D iterative approach to reduce metal artifact”. In: *American Journal of Neuroradiology* 36.10 (2015), pp. 1988–1993.

- [171] Michael D Ketcha et al. “Effects of image quality on the fundamental limits of image registration accuracy”. In: *IEEE transactions on medical imaging* 36.10 (2017), pp. 1997–2009.
- [172] Kai Yang et al. “CT image quality evaluation in the age of deep learning: trade-off between functionality and fidelity”. In: *European Radiology* 33.4 (2023), pp. 2439–2449.
- [173] Shahrukh Athar and Zhou Wang. “A comprehensive performance evaluation of image quality assessment algorithms”. In: *Ieee Access* 7 (2019), pp. 140030–140070.
- [174] Albert J Ahumada. “Computational image quality metrics: A review”. In: *SID Digest* 24 (1993), pp. 305–308.
- [175] Marcondes Ricarte da Silva Júnior et al. “Image Quality Assessment in the Context of the Brazilian Electoral System.” In: *VISIGRAPP (4: VISAPP)*. 2023, pp. 444–451.
- [176] Praveen Kandula, Maitreya Suin, and AN Rajagopalan. “Illumination-adaptive unpaired low-light enhancement”. In: *IEEE Transactions on Circuits and Systems for Video Technology* 33.8 (2023), pp. 3726–3736.
- [177] Mingjia Li, Hao Zhao, and Xiaojie Guo. “LIME-Eval: Rethinking Low-light Image Enhancement Evaluation via Object Detection”. In: *arXiv preprint arXiv:2410.08810* (2024).
- [178] Sergey Kastrayulin et al. “Image quality assessment for magnetic resonance imaging”. In: *IEEE Access* 11 (2023), pp. 14154–14168.
- [179] Lucie Lévesque et al. “Comparative study of the methodologies used for subjective medical image quality assessment”. In: *Physics in Medicine & Biology* 66.15 (2021), 15TR02.
- [180] Muhammad Waqar Mirza, Asif Siddiq, and Ishtiaq Rasool Khan. “A comparative study of medical image enhancement algorithms and quality assessment metrics on COVID-19 CT images”. In: *Signal, Image and Video Processing* 17.4 (2023), pp. 915–924.
- [181] Changhoon Yim and Alan Conrad Bovik. “Quality assessment of deblocked images”. In: *IEEE Transactions on Image Processing* 20.1 (2010), pp. 88–98.
- [182] Adel Almohammad and Gheorghita Ghinea. “Stego image quality and the reliability of PSNR”. In: *2010 2nd International Conference on Image Processing Theory, Tools and Applications*. IEEE. 2010, pp. 215–220.
- [183] Kashif Shaheed and Imran Qureshi. “A hybrid proposed image quality assessment and enhancement framework for finger vein recognition”. In: *Multimedia Tools and Applications* 83.5 (2024), pp. 15363–15388.
- [184] S Kevin Zhou et al. “A review of deep learning in medical imaging: Imaging traits, technology trends, case studies with progress highlights, and future promises”. In: *Proceedings of the IEEE* 109.5 (2021), pp. 820–838.
- [185] Luciano M Prevedello et al. “Challenges related to artificial intelligence research in medical imaging and the importance of image analysis competitions”. In: *Radiology: Artificial Intelligence* 1.1 (2019), e180031.
- [186] Fuzhen Zhuang et al. “A comprehensive survey on transfer learning”. In: *Proceedings of the IEEE* 109.1 (2020), pp. 43–76.

- [187] Hee E Kim et al. “Transfer learning for medical image classification: a literature review”. In: *BMC medical imaging* 22.1 (2022), p. 69.
- [188] Davood Karimi, Simon K Warfield, and Ali Gholipour. “Transfer learning in medical image segmentation: New insights from analysis of the dynamics of model parameters and learned representations”. In: *Artificial intelligence in medicine* 116 (2021), p. 102078.
- [189] Maithra Raghu et al. “Transfusion: Understanding transfer learning for medical imaging”. In: *Advances in neural information processing systems* 32 (2019).
- [190] Alexander Kirillov et al. “Segment anything”. In: *Proceedings of the IEEE/CVF international conference on computer vision*. 2023, pp. 4015–4026.
- [191] Jun Ma et al. “Segment anything in medical images”. In: *Nature Communications* 15.1 (2024), p. 654.
- [192] YiNan Zhang and MingQiang An. “Deep learning-and transfer learning-based super resolution reconstruction from single medical image”. In: *Journal of healthcare engineering* 2017.1 (2017), p. 5859727.
- [193] Florian Knoll et al. “Assessment of the generalization of learned image reconstruction and the potential for transfer learning”. In: *Magnetic resonance in medicine* 81.1 (2019), pp. 116–128.
- [194] Jiasi Chen and Xukan Ran. “Deep learning with edge computing: A review”. In: *Proceedings of the IEEE* 107.8 (2019), pp. 1655–1674.
- [195] Yue Zheng et al. “A review on edge large language models: Design, execution, and applications”. In: *ACM Computing Surveys* 57.8 (2025), pp. 1–35.
- [196] Antti Isosalo et al. “Local edge computing for radiological image reconstruction and computer-assisted detection: A feasibility study”. In: *Finnish Journal of eHealth and eWelfare* 15.1 (2023), pp. 52–66.
- [197] Jing Zhang et al. “3D remote healthcare for noisy CT images in the internet of things using edge computing”. In: *IEEE Access* 9 (2021), pp. 15170–15180.
- [198] Shiqian Zhang et al. “A collaborative inference strategy for medical image diagnosis in mobile edge computing environment”. In: *PeerJ Computer Science* 11 (2025), e2708.
- [199] Jianping Gou et al. “Knowledge distillation: A survey”. In: *International Journal of Computer Vision* 129.6 (2021), pp. 1789–1819.
- [200] Feng Zhou et al. “Distillation Learning Guided by Image Reconstruction for One-Shot Medical Image Segmentation”. In: *arXiv preprint arXiv:2408.03616* (2024).
- [201] Zhengliang Wu and Xuesong Li. “Adaptive knowledge distillation for high-quality unsupervised mri reconstruction with model-driven priors”. In: *IEEE Journal of Biomedical and Health Informatics* 28.6 (2024), pp. 3571–3582.
- [202] Steven M Williamson and Victor Prybutok. “Balancing privacy and progress: a review of privacy challenges, systemic oversight, and patient perceptions in AI-driven healthcare”. In: *Applied Sciences* 14.2 (2024), p. 675.

- [203] Danyang Li et al. “Noise characteristics modeled unsupervised network for robust CT image reconstruction”. In: *IEEE Transactions on Medical Imaging* 41.12 (2022), pp. 3849–3861.
- [204] Hemant Kumar Aggarwal et al. “ENSURE: A general approach for unsupervised training of deep image reconstruction algorithms”. In: *IEEE transactions on medical imaging* 42.4 (2022), pp. 1133–1144.
- [205] Yuanhao Cai et al. *Structure-Aware Sparse-View X-ray 3D Reconstruction*. 2024. arXiv: 2311.10959 [eess.IV]. URL: <https://arxiv.org/abs/2311.10959>.
- [206] Happiness Ugochi Dike et al. “Unsupervised learning based on artificial neural network: A review”. In: *2018 IEEE International Conference on Cyborg and Bionic Systems (CBS)*. IEEE. 2018, pp. 322–327.
- [207] Hao Guan et al. “Federated learning for medical image analysis: A survey”. In: *Pattern Recognition* (2024), p. 110424.
- [208] Chun-Mei Feng et al. “Specificity-preserving federated learning for MR image reconstruction”. In: *IEEE Transactions on Medical Imaging* 42.7 (2022), pp. 2010–2021.
- [209] Gokberk Elmas et al. “Federated learning of generative image priors for MRI reconstruction”. In: *IEEE Transactions on Medical Imaging* 42.7 (2022), pp. 1996–2009.
- [210] Hao Guan and Mingxia Liu. “Domain adaptation for medical image analysis: a survey”. In: *IEEE Transactions on Biomedical Engineering* 69.3 (2021), pp. 1173–1185.
- [211] Yoseob Han et al. “Deep learning with domain adaptation for accelerated projection-reconstruction MR”. In: *Magnetic resonance in medicine* 80.3 (2018), pp. 1189–1205.
- [212] Jee Seok Yoon et al. “Domain Generalization for Medical Image Analysis: A Review”. In: *Proceedings of the IEEE* (2024).
- [213] Yutian Zhao, Tianjing Zhang, and Hui Ji. “Test-Time Model Adaptation for Image Reconstruction Using Self-supervised Adaptive Layers”. In: *European Conference on Computer Vision*. Springer. 2024, pp. 111–128.
- [214] Yufan He et al. “Autoencoder based self-supervised test-time adaptation for medical image analysis”. In: *Medical image analysis* 72 (2021), p. 102136.
- [215] Alexander Ziller et al. “Medical imaging deep learning with differential privacy”. In: *Scientific Reports* 11.1 (2021), p. 13524.
- [216] Yang Yang et al. “A secure and high visual-quality framework for medical images by contrast-enhancement reversible data hiding and homomorphic encryption”. In: *IEEE Access* 7 (2019), pp. 96900–96911.
- [217] Francis Dutil et al. “Application of homomorphic encryption in medical imaging”. In: *arXiv preprint arXiv:2110.07768* (2021).
- [218] Peng Xi et al. “A review of Blockchain-based secure sharing of healthcare data”. In: *Applied Sciences* 12.15 (2022), p. 7912.
- [219] Meng Shen et al. “Privacy-preserving image retrieval for medical IoT systems: A blockchain-based approach”. In: *Ieee Network* 33.5 (2019), pp. 27–33.

- [220] Christopher Ifeanyi Eke and Liyana Shuib. “The role of explainability and transparency in fostering trust in AI healthcare systems: a systematic literature review, open issues and potential solutions”. In: *Neural Computing and Applications* (2024), pp. 1–36.
- [221] Zohaib Salahuddin et al. “Transparency of deep neural networks for medical image analysis: A review of interpretability methods”. In: *Computers in biology and medicine* 140 (2022), p. 105111.
- [222] Kunpeng Li et al. “Tell me where to look: Guided attention inference network”. In: *Proceedings of the IEEE conference on computer vision and pattern recognition*. 2018, pp. 9215–9223.
- [223] Oscar Li et al. “Deep learning for case-based reasoning through prototypes: A neural network that explains its predictions”. In: *Proceedings of the AAAI conference on artificial intelligence*. Vol. 32. 1. 2018.
- [224] Ramprasaath R Selvaraju et al. “Grad-cam: Visual explanations from deep networks via gradient-based localization”. In: *Proceedings of the IEEE international conference on computer vision*. 2017, pp. 618–626.
- [225] Mukund Sundararajan, Ankur Taly, and Qiqi Yan. “Axiomatic attribution for deep networks”. In: *International conference on machine learning*. PMLR. 2017, pp. 3319–3328.
- [226] Hao Zhang et al. “Deep unfolding network with spatial alignment for multi-modal mri reconstruction”. In: *Medical Image Analysis* 99 (2025), p. 103331.

致 谢

本文的英文版本已发表于 arXiv (<https://arxiv.org/abs/2504.11349>), 并已投稿至医学图像分析领域的顶级期刊 *Medical Image Analysis (MedIA)*。感谢计算机视觉课程张鹏老师在学习过程中给予的启发与支持。本文在撰写过程中亦得到了董兴波老师和金哲教授的悉心指导与宝贵建议。此外, 其他合著者在文献的收集与整理方面提供了重要帮助。还感谢加拿大阿尔伯塔大学的 Li Cheng 教授在研究中的指导支持, 目前我仍在其指导下开展相关研究工作 (该研究亦得到了 CSC 资金资助)。